TARTU ÜLIKOOL
MATEMAATIKA-INFORMAATIKATEADUSKOND
Matemaatika instituut
Matemaatika eriala

Vootele Rõtov

Valikvastustega küsimustike reliaabluse hindamine

Bakalaureusetöö (6 EAP)

Juhendaja: Margus Niitsoo

TARTU 2014

Valikvastustega küsimustike reliaabluse hindamine

Vootele Rõtov

Lühikokkuvõte

Käesolev bakalaureusetöö vaatleb erinevaid võimalusi valikvastustega küsimustike reliaabluse hindamiseks küsimustiku ühekordse läbiviimise põhjal.

Töö käigus antakse lugejale vajaminevad taustteadmised valikvastustega küsimustikest ning nende karakteristikutest, defineeritakse reliaablus klassikalise testiteooria raamistikus ja antakse vajalik matemaatiline baas reliaabluse hinnangute tuletamiseks. Seejärel tuletatakse viis hinnangut reliaablusele, hinnatakse nende kasutatavust praktikas ja tutvustatakse autori poolt loodud programmiteeki, mis sisaldab programme tuletatud hinnangute leidmiseks testi läbiviimisel saadud andmete põhjal.

Töö annab eesti keelse ülevaate klassikalisest testiteooriat alustest matemaatilisest vaatepunktist lähtudes ning tutvustab praktikule erinevaid võimalusi testi reliaabluse hindamiseks, kusjuures tutvustatake meetodeid, mis annavad paremaid tulemusi, kui hetkel enamlevinud meetodid.

VÕTMESÕNAD: psühhomeetria, klassikaline testiteooria, valikvastustega küsimustikud, reliaablus, reliaabluse hindamine, Cronbachi alfa, Guttmani lambdad, glb.

On the Reliability of Likert Scale Questionaries

Vootele Rõtov

Abstract

This bachelor's thesis is to give an overview of different possibilites of estimating reliability of Likert scale questionaries based on single admission.

The thesis contains a short overview of neccesary background information about Likert scales and their characteristics, definition of reliability in context of Classical Test Theory and mathematical basis for deriving estimations of reliabiliby. Also, five estimates are derived and their usability in practise is discussed. Finally author gives a short overview of programming library that implements methods for finding derived estimates based on data gathered from admissioning the questionarie.

Thesis gives an overview of foundation of Classical Test Theory in Estonian from mathematical viewpoint and introduces different possibilites for estimating the reliability of questionarie, some of what give better results than the ones in widespeard use today.

KEYWORDS: psychometrics, classical test theory, Likert scale questionaries, reliability, estimating reliability, Cronbach's alfa, Guttman's lambdas, glb.

Sisukord

1 Sissejuhatus

Käesolev bakalaureusetöö on motiveeritud psühholoogide probleemist - kuidas hinnata nende töövaldkonnas tihti kasutatavate valikvastustega küsimustike usaldusväärsust.

Sellest lähtuvalt on töö põhieesmärgiks pakkuda valikvastustega küsimustike hindamiseks lihtsasti kasutatavaid kvantitatiivseid meetodeid. Lisaks sellele loodab autor pakkuda eestikeelset ülevaadet ühest valikvastustega testidega seotud matemaatiliselt raamistikust - olemasolevad käsitlused on pigem praktilised abivahendid psühholoogidele.

Töö esimeses osas anname vajaliku taustinfo, definitsioonid ja probleemipüstituse. Seejärel ehitame üles meile vajamineva osa probleemi vaatlemiseks sobivast matemaatilisest teooriast - defineerime testi usaldusväärsuse ning rajame vundamendi selle hindamiseks. Järgnevalt tuletame mõningaid erinevad usaldusväärsuse hinnangud. Töö viimases osas tutvustame autori poolt loodud programmiteeki, mis sisaldab eelnevalt tutvustatud hinnangute implementatsioone.

Autori eesmärgiks on see, et antud tekst oleks lihtsasti järgitav keskmisele bakalaureuseõpe läbinud matemaatikatudengile - valdkonna spetsiifilised matemaatilised definitsioonid ja tulemused on meeldetuletuseks töö käigus jooksvalt ära toodud.

Lisaks loodab autor, et loodud programmiteek pakkub huvi ka psühholoogidele.

2 Taustinfo ja probleemipüstitus

Järgnevalt anname vajalikud taustateadmised probleemi mõtestamiseks ning peatüki lõpetuseks püstitame käesoleva töö keskse probleemi.

2.1 Küsimustik, küsimus ja Likerti skaala

Käesolev uurimus tegeleb küsimustikega (*Likert scale*), milles soovitakse hinnanguid teatud arvule küsimustele (*Likert item*) n pallisel Likerti skaalal [5], kus n jääb enamasi kahe ja kümne vahele. Käsitleme Likerti skaalasid, mis on sümmeetrilised, see tähendab, et positiivsete ja negatiivsete vastuse variantide arv on sama. Näiteks:[①]

Käesoleva bakalaureusetöö ülesehitus on loogiline.

☐ Ei nõustu ☐ Ei nõustu osaliselt ☐ Nii ja naa ☐ Nõustun osaliselt ☑ Nõustun

Joonis 1: Näide väitest, millele palutakse hinnangut Likerti skaalal

2.2 Likerti skaala tõlgendamine intervallskaalana

Likerti skaala tõlgendamisel intervallksaalana on väljakujunenud tava seada valikvastustele vastavusse järjestatud täisarvud, kusjuures mida positiivsem vastuseevariant, seda suurem temale vastavusse seatud arv. Reeglina kasutatakse kas arve alates ühest kuni valikvastuste arvuni või valitakse välja täisarvud nii, et neutraalsele vastusevariandile vastab null.

Käesoleva bakalaureusetöö ülesehitus on loogiline.

-2	-1	0	1	2
↑	↑	↑	↑	↑
☐ Ei nõustu	☐ Ei nõustu osaliselt	☐ Nii ja naa	☑ Nõustun osaliselt	☐ Nõustun
↓	↓	↓	↓	↓
1	2	3	4	5

Joonis 2: Näide kahest levinumast Likerti skaala tõlgendusest invtervallskaalana

[①]Näited terviklikest küsimustikest on lisades, joonisel 10 ja 11

Lugejal võib tekkida õigustatud küsimus, kuidas põhjendab autor Likerti skaala käsitlemist intervallskaalana, kui Likerti skaala on olemuseslt järjestikskaala ning selle tõlgendamises intervallskaalana on vastuoluline küsimus, näiteks [9]. Siinkohal tõdeme, et Likerti skaala tõlgendamine intervallksaalana on praktikas piisavalt levinud, et selle valdkonna uurimine õigustatud oleks - olenamat selle teoreetilisest põhjendatusest. Siinkohal väärib autori silmis esile toomist kriitikute üks levinumaid argumente - „hea“ ja „väga hea“ keskmine ei ole loomulikul viisil tõlgendatav kui „hea + pool“ ehk pole mingit põhjust eeldada, et kõikide küsimuste omavaheline kaugus on mingil põhjusel võrdne.

2.3 Küsimustiku valiidsus

Küsimustiku **valiidsus** on küsimustiku karakteristik, mis iseloomustab testi võimet mõõta seda, mida ta disainiti mõõtma. Enamikes käsitlustes vaadeltakse valiidsust kui väärtust intervall skaalal nulli ja ühe vahel.

Näitena, olgu meil küsimustikuks kaal, mille näitu vaatleme kui küsimustiku tulemust kaalutava isiku puhul. Kaal, mis näitab 75 kilo kaaluva inimese kaaluks 74,5 kilo omab kõrgemat valiidsust kui kaal, mis sama inimese puhul näitab kaaluks 65 kilo.

Arusaadavatel põhjustel on testi valiidsus äärmiselt oluline ning psühholoogiliste testide valiidsuse hindamine on olnud üks psühhomeetria põhilistest uurimisobjektidest. Sellega seoses on palju tööd tehtud ka valiidsuse definitsiooni täpsemaks muutmisega, võrreldes selle paragrahvi alguses antud väga intuitiivse definitsiooniga. Kuna valiidsus on selle töö raames vajalik vaid taustinfona probleemi mõttestamisel tundub antud lihtne definitsioon aga sobivaim.

2.4 Küsimustiku reliaablus

Küsimustiku **reliaablus** on küsimustiku karakteristik, mis kirjeldab, kui järjepidevad on subjekti erinevated mõõtmised sama küsimustikuga ehk küsimustiku stabiilsus. Nagu valiidsus, on ka reliaablus reeglina määratud intervall skaalal, nulli ja ühe vahel.

Näitena, kaal mis näitab 75 kilo kaaluva inimese kaaluks 74,5 kilo igal kaalumisel omab kõrgemat reliaablust kui kaal, mis näitab juhuslikult kas 74,5 kilo või 75,5 kilo.

Reliaabluse täpsema, matemaatilise definitsioone anname edaspidi.

2.5 Valiidsuse ja reliaabluse suhe

Valiidsuse ja reliaabluse suhestamisel kerkib kiiresti üles loomulik küsimus - kas test võib olla samaaegselt suure valiidsuse ja väikse reliaablusega? Eelpool antud definitsioonid jättavad selle küsimuse lahtiseks - vaatleme järgmist olukorda:

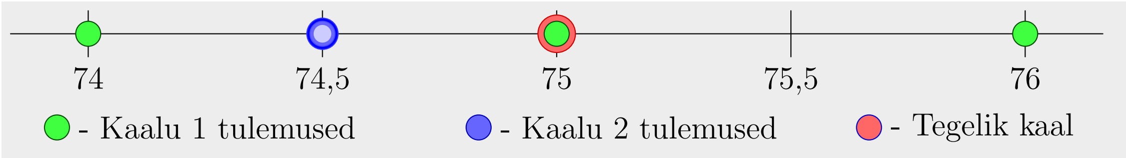

Joonis 3: Kaalumiste tulemused kahe erineva kaaluga kolmel katsel

Kui mõista valiidsust kui küsimusitku keskmist tulemust, siis võime väita, et esimene kaal on väiksema reliaabluse aga suurema valiidsusega. Selline valiidsuse mõttestamine aga ei ole küsimustike modeleleerimise korral otstarbekas - katsete kordamine on enamasti keeruline ning väheste mõõtmistulemuste põhjal ei ole võimalik tegeliku väikese reliaablusega testi tulemust välja selgitada.

Seega, meie vaadeldava olukorra - psühholoogiliste testide - korral on mingi valiidsuse taseme jaoks tarvilik tingimus mingi reliaabluse tase.

2.6 Sisemine järjepidevus

Reliaabluse kui termini probleemiks on tema mitmetähenduslikus. Toome siinkohal ära ühe mõiste, mida tihti samuti reliaablusena või sisemise järjepidevuse reliaablusena tuntakse.

Sisemine järjepidavus (*internal consistency*) on küsimustiku karrakteristik, mis iseloomustab testi erinevate küsimuste vastuste järjepidevust ehk seda, kui hästi on kooskõlas vastused ühist konstruktsiooni hindavatele küsimustele [7, 177]. Paneme tähele, et erinevalt eelnevalt toodud reliaabluse definitsioonist, on sisemine järjepidevus ühe testi läbiviimise keskne. Piltlikult väljendudes, olgu meil järgnev küsimustik:

Käesoleva bakalaureusetöö ülesehitus on loogiline.

☐ Ei nõustu ☐ Ei nõustu osaliselt ☐ Nii ja naa ☐ Nõustun osaliselt ☐ Nõustun

Mulle meedlib käesoleva bakalaureusetöö ülesehitus.

☐ Ei nõustu ☐ Ei nõustu osaliselt ☐ Nii ja naa ☐ Nõustun osaliselt ☐ Nõustun

Käesolevat bakalaureusetööd on lihtne lugeda.

☐ Ei nõustu ☐ Ei nõustu osaliselt ☐ Nii ja naa ☐ Nõustun osaliselt ☐ Nõustun

Joonis 4: Küsimustik bakalaureusetöö ülesehituse kohta

Siin on mõõdetavaks konstruktsiooniks käesoleva bakalaureusetöö ülesehitus ning kõrgeks sisemiseks reliaabluseks on vajalik kolmele näites toodud küsimusele antud vastuste kooskõla.

Selleks, et sisemine järjepidavus oleks mõtestatud peavad meil küsimustikus olema mingi kindla konstruktsiooni mõõtmiseks rohkem kui üks küsimus - vastasel juhul on iga küsimus täielikus kooskõlas kõikide sama konstruktsiooni mõõtvate küsimustega, ehk iseendaga. Rõhutame, et see nõue ei laiene eelnevalt defineeritud reliaablusele.

Sisemise järjepidavuse mõõtmiseks on võimalik kasutada sisemise järjepidavuse teste. Segadust suurendab veelgi see, et üks nendest testidest leiab kasutamist ka meie poolt defineeritud reliaabluse hindamisel. Loodame, et nende kahe karakterisitku eristamine aitab lugejal käesolevas töös kergemini orienteeruda.

Märgime, et lisaks toodud kahele definitsioonile on ka teisi reliaabluse käsitlusi [1], mis aga selle töö kontekstis ei tohiks segadust tekitada ning mille äratoomist siin ei ole autor pidanud vajalikus.

2.7 Probleemi püstitus

Käesoleva tööga üritame pakkuda lahendust järgnevale praktilisele probleemile - kas on võimalik leida paremat hinnangut küsimustiku reliaablusele kui seda on tihti kasutatav Guttmani λ_3 (rohkem tuntud kui Cronbachi α)?

Küsimusele vastamiseks on meil vaja rangemat lähenemist reliaablusele ning selleks vaatleme reliaablust ühe matemaatilise raamistiku - klassikalise testiteooria - kontekstis.

3 Reliaablus klassikalises testiteoorias

Järgevas võtame aluseks Melvin Novicki klassikalise testiteooria [12] [11] ja selle tõlgenduse Klaas Sijtsma poolt. [14, 109]

3.1 Reliaabluse definitsioon

MEELDETULETUSEKS

Definitsioon. *Elementaarsündmuseks* nimetatakse juhusliku katse võimaliku tulemust.
Definitsioon. *Tõenäosuseks* nimetatakse funktsiooni P, mis igale sündmusele $A \in 2^{\Omega}$, kus Ω on mingi juhusliku katse kõikvõimalikke elementaarsündmuste hulk, seab vastavusse arvu $P(A)$, nii et on täidetud järgmised nõuded:

1. $P(A) \geq 0, \forall A \in 2^{\Omega}$,
2. $P(\Omega) = 1$, $P(\emptyset) = 0$,
3. Kui sündmused $A_1, A_2, ...$ on teineteist välistavad, siis

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P\left(A_i\right)$$

.

Definitsioon. *Diskreetseks juhuslikus suuruseks* nimetatakse funktsiooni $X : \Omega \to \mathbb{R}$, mis võtab kas lõpliku või loenduva arvu erinevaid väärtusi $x_1, x_2, ...(x_n)$.

Olgu meil mingi kogum I testile vastajaid ning küsimustik, milles on k küsimust, kus iga küsimus on l-pallisel Likerti skaalal. Nummerdame küsimused naturaalarvudega 1 kuni k. On loomulik eeldada, et nii vastajate arv, küsimuste arv kui ka Likerti skaala suurus on lõplikud. Me võime vaadelda testi läbiviimist kui juhusliku katset ning kõiki erinevaid võimalikke vastuste kombinatsioone küsimustikule kui elementaarsündmusi, tähistame saadud elementaarsündmuste hulga kui Ω ning elementaarsündmusi kui ω. Eeldame ka tõenäosuste $P_i : 2^{\Omega} \to \mathbb{R}$ olemasolu, mida tõlgendame kui testi tulemuste esinemissagededust vastaja i korral.

Küsimus / ω	I	II	II
A	Nõustun osaliselt	Nii ja naa	Nõustun
B	Ei nõustu osaliselt	Nõustun	Nii ja naa
C	Ei nõustu	Nõustun osaliselt	Nii ja naa

Joonis 5: Näited elementaarsündmustest

Olgu X_i^j hulgal Ω määratud juhuslik suurus, mille võimalike väärtusi vaatleme kui vastaja i poolt küsimusele j antud vastuse arvulist tõlgendust. On selge, et sellise tõlgenduse korral on juhusliku suuruse X_i^j muutumispiirkond lõplik - selle hulga võimsus ei ole suurem kui l ning järelikult on juhuslik suurus X_i^j diskreetne. Defineerime vastaja i testi tulemuse X_i kui

$$X_i = \sum_{j=1}^{k} X_i^j.$$

Paneme tähele, et X_i on samuti diskreetne juhuslik suurus - tõepoolest, kuna tegemist on diskreetsete juhuslike suuruste summaga, siis on ta funktsioon hulgast Ω hulka $\mathbb{R}$. Lisaks, kuna kõikide liidetavate muutumispiirkond on tõkkestatud arvuga l ning liidetavaid on k, siis ei saa funktsiooni muutumispiirkonna võimsus olla suurem kui l^k.

MEELDETULETUSEKS

Definitsioon. Disktreetse juhusliku suuruse X *jaotuseks* nimetatakse paaride komplekti $(x_i, p_i), i = 1, 2, ...,$ kus x_i on juhusliku suuruse võimalik väärtus ning $p_i = P(\{\omega | X(\omega) = x_i, \omega \in \Omega\})$.
Definitsioon. Diskreetse juhusliku suuruse X, mille jaotuseks K on paaride komplekt $k_i = (x_i, p_i), i = 1, 2, ...,$ *keskväärtuseks* nimetatakse arvu

$$\epsilon X = \sum_{\{i | k_i \in K\}} x_i p_i$$

eeldusel, et see rida koondub absoluutselt.
Definitsioon. Juhusliku suuruse X *dispersiooniks* nimetatakse arvu $DX = \epsilon\left[(X - \epsilon X)^2\right]$.

Triviaalse juhu vältimiseks eeldame edaspidi, et juhuslike suuruste X_i dispersioonid on nullist erinevad. Defineerime küsimustiku tegeliku tulemuse vastaja i jaoks kui testi tulemuse keskväärtuse ehk

$$t_i = \epsilon\,[X_i]\,.$$[2]

Kuna juhusliku suuruse X_i võimalike väärtuste arv on lõplik on ka tema keskväärtus t_i lõplik.

Tõlgendame vastaja i testi tulemuse ja tegeliku tulemuse vahet mõõtmisveana, tähistame seda E_i. Seega $X_i = t_i + E_i$.

MEELDETULETUSEKS

Lause 3.1. Kui X on diskreetne juhuslik suurus, jaotusega K, kus K on paaride komplekt $k_i = (x_i, p_i), i = 1, 2, ...$ ning c on mingi konstant siis $\epsilon(X + c) = \epsilon(X) + c$

Tõestus.

$$\epsilon(X + c) = \sum_{\{i|k_i \in K\}} (x_i + c)p_i = \sum_{\{i|k_i \in K\}} x_i p_i + \sum_{\{i|k_i \in K\}} c p_i =$$
$$= \sum_{\{i|k_i \in K\}} x_i p_i + c \sum_{\{i|k_i \in K\}} p_i = \sum_{\{i|k_i \in K\}} x_i p_i + c = \epsilon(X) + c$$

□

Lause 3.2. Juhuslikule suurusele konstandi liitmine ei muuda dispersiooni : $D(X + c) = DX$

Tõestus.

$$D(X+c) = \epsilon[X+c-\epsilon(X+c)] \overset{\text{Lause 3.1}}{=} \epsilon[X+c-\epsilon(X)+c] = \epsilon[X-\epsilon(X)] = DX$$

□

Paneme tähele, et eelneva põhjal on vastaja i mõõtmisvea keskväärtus võrdne nulliga. Tõepoolest, kuna tegeliku tulemuse definitsiooni põhjal $\epsilon\,[X_i] = t_i$, siis saame mõõtmisvea definitsiooni arvesse võttes

$$t_i = \epsilon\,[X_i] = \epsilon\,[t_i + E_i] \overset{\text{Lause 3.1}}{=} t_i + \epsilon\,[E_i] \implies \epsilon\,[E_i] = 0.$$

[2] Tähistame keskväärtuse tähega ϵ kuna tavapärane tähistus E leiab antud käsitluses teistsuguse rolli.

Lisaks on lihtne märgata, et $D[X_i] = D[E_i]$, sest

$$D[X_i] = D[E_i + t_i] \overset{\text{Lause 3.2}}{=} D[E_i].$$

Eelnevates definitsioonides keskendusime testi tulemuste mõtestamisele fikseeritud vastaja korral. Kuna reeglina mõtestatakse teste praktikas mingi vastajate kogumi raames, siis keskendume ka meie edaspidi sellele.

Vaatleme elementaarsündmustena hulga $I \times \Omega$ elemente ning eeldame, et eksisteerib tõenäosus

$$P_p : 2^{I \times \Omega} \to \mathbb{R},$$

kus funktsiooni P_p tõlgendame kui isiku $i \in I$ ja testi tulemuse $\omega \in \Omega$ koos esinemis sagedust.

Paneme tähele, et sellel elemntaarsündmuste hulgal võime määrata diskreetse juhusliku suuruse T, nii et

$$T((i, \omega)) = t_i, i \in I.$$

Seda juhuliku suurust tõlgendame kui küsimustiku tegelikku tulemust. Defineerime testi vaadeldava tulemuse kui diskreetse juhusliku suuruse X, nii et

$$X(i, \omega)) = X_i(\omega)$$

ja testi vea kui diskreetse juhusliku suuruse E, nii et

$$E((i, \omega)) = E_i(\omega).$$

Paneme tähele, et kehtib $X = E + T$, tõepoolest olgu meil suvaline paar $(i, \omega) \in I \times \Omega$, siis

$$X((i, \omega)) = X_i(\omega) \overset{def}{=} t_i + E_i(\omega) = T((i, \omega)) + E((i, \omega)).$$

Eeldame edaspidises, et X ei ole konstante juhuslik suurus - kui X on konstante, siis .

MEELDETULETUSEKS

Definitsioon. Juhusliku suuruste X ja Y *kovariatsiooniks* nimetatakse suurust

$$cov(X,Y) = \epsilon\left[(X - \epsilon X)(Y - \epsilon Y)\right].$$

Definitsioon. Juhusliku suuruste X ja Y *korrelatsioonikordajaks* nimetatakse suurust

$$\rho(X,Y) = \frac{cov(X,Y)}{\sqrt{DX}\sqrt{DY}}$$

Esitame nüüd meie poolt üles ehitatud mudeli omaduse, mis osutub väga kasulikus. Olgu meil kaks suvalist küsimustiku, mille vaadeldavad tulemused on vastavalt $X = T + E$ ja $X' = T' + E'$, siis kehtib

$$cov(T, E') = 0, \tag{3.3}$$

ehk mingi küsimustiku tegeliku tulemuse ja mingi küsimustiku mõõtmisvea vahel ei ole korrelatsiooni. See omadus muudab mudeli rakendamise palju lihtsamaks, kuna me ei pea eeldame, et meie poolt koostatud küsimustikul on selline omadus. Tõestus sellele omadusele kahjuks käesoleva töö raamidesse ei mahu, rangest tõestusest huvitatutele soovitame tutvuda Donald Zimmermani mudeli ülesehitusega [19].

Paneme tähele, et kuna me ei seadunud mingeid kitsendusi testide X ja X' jaoks, siis ka $cov(T, E) = 0$.

Küll aga peame me tegema järgneva eelduse - olgu meil kaks erinevat küsimustiku, mille mõõtmisvead on vastavalt E ja E' siis

$$cov(E, E') = 0. \tag{3.4}$$

Tehtud eeldus tähendab seda, et mõõtmisvead ei tohi olla süstemaatilised. Näiteks, jagades küsimustiku pooleks ning vaadeldes mõlemat osa kui eraldi küsimustiku, siis teades esimese mõõtmisviga ei tohiks see meile midagi öelda teise osa mõõtmisvea kohta. Paneme tähele, et see eeldus on siimaani tehtutest praktikas kõige raskemini tagatav ning on potensiaalne ohukoht testiteooria kasutamisel mingi küsimustiku mõtestamisel.

MEELDETULETUSEKS

Lause 3.5. Juhuslikke suuruste X ja Y puhul kehtib

$$D(X+Y) = D(X) + D(Y) + 2cov(X,Y)$$

Tõestus.

$$D(X+Y) \overset{def}{=} \epsilon[X+Y-\epsilon(X+Y)]^2 \overset{\epsilon \text{ lin.}}{=} \epsilon[X-\epsilon X+Y+\epsilon Y]^2 =$$
$$= \epsilon(X-\epsilon X)^2 + 2\epsilon(X-\epsilon X)(Y-\epsilon Y) + \epsilon(Y-\epsilon Y)^2 \overset{\text{cov def}}{=}$$
$$= D(X) + D(Y) + 2cov(X,Y)$$

□

Järgnevalt tutvume paralleelse küsimustiku mõistega. Kaks küsimustiku, mille vaadeldavad tulemused üle kõigi vastajate kogumi I on $X = T + E$ ja $X' = T' + E'$ ning mille vaadeldavad tulemused vastaja $i \in I$ jaoks on $X_i = t_i + E_i$ ja $X_i' = t_i' + E_i'$, on paralleelsed parajasti siis, kui kehtivad järgmised väited :

1. $t_i = t_i'$ $\forall i \in I$,
2. $D[E] = D[E']$.

Eelnevast järeldub lihtsalt, et

$$T = T'. \tag{3.6}$$

Tõepoolest, olgu (i, ω) suvaline paar hulgast $I \times \Omega$, siis kehtib

$$T((i,\omega) \overset{def}{=} t_i = t_i' = T'((i,\omega)).$$

Pange tähele, et kahe paraleelse küsimustiku X ja X' korral kehtib

$$D[X] = D[X'], \tag{3.7}$$

kuna

$$D[X] = D[T+E] \overset{\text{Lause 3.5}}{=} D[T] + D[E] + 2cov(T,E) \overset{(3.3)}{=} D[T] + D[E] =$$
$$= D[T'] + D[E'] = D[T'] + D[E'] + 2cov(T',E') = D[T'+E'] = D[X'].$$

MEELDETULETUSEKS

Lause 3.8. Olgu meil juhuslikud suurused X, Y ja Z. Siis

$$cov(X+Y,Z) = cov(X,Z) + cov(Y,Z).$$

Tõestus.

$$\begin{gathered}
cov(X+Y,Z) \overset{def}{=} \epsilon\left[(X+Y-\epsilon\left[X+Y\right])(Z-\epsilon\left[Z\right])\right] \overset{\epsilon \text{ lin.}}{=} \\
= \epsilon\left[(X+Y-\epsilon\left[X\right]+\epsilon\left[Y\right])(Z-\epsilon\left[Z\right])\right] = \\
= \epsilon\left[\left((X-\epsilon\left[X\right])+(Y-\epsilon\left[Y\right])\right)(Z-\epsilon\left[Z\right])\right] = \\
= \epsilon[(X-\epsilon\left[X\right])(Z-\epsilon\left[Z\right])+(Y-\epsilon\left[Y\right])(Z-\epsilon\left[Z\right])] = \\
= \epsilon\left[(X-\epsilon\left[X\right])(Z-\epsilon\left[Z\right])\right]+\epsilon\left[(Y-\epsilon\left[Y\right])(Z-\epsilon\left[Z\right])\right]+ \\
= cov(X,Z)+cov(Y,Z)
\end{gathered}$$

□

Paralleelse küsimustiku abil saame klassikalise testiteooria raames defineerida reliaabluse. Olgu meil kaks paralleelset küsimustiku, mille vaadeldavad tulemused üle vastajate kogumi I on vastavalt $X = T + E$ ja $X' = T' + E'$. Testi, mille vaadeldav tulemus on X, reliaablus üle vastajate kogumi I on võrdne X ja X' korrelatsioonikordajaga, mida tähistame $\rho_{XX'}$, formaalselt

$$\rho_{XX'} = corr\left(X, X'\right).$$

Eelneva põhjal saame näidata, et kehtib

$$\begin{gathered}
\rho_{XX'} \overset{def}{=} \frac{cov(X,X')}{\sqrt{D\left[X\right]D\left[X'\right]}} \overset{(3.7)}{=} \frac{cov(X,X')}{\sqrt{D\left[X\right]D\left[X\right]}} = \frac{cov(T+E,T'+E')}{D\left[X\right]} \overset{\text{Lause 3.8}}{=} \\
= \frac{cov(T,T')+cov(T,E')+cov(E,T')+cov(E,E')}{D\left[X\right]} \overset{(3.3)}{=} \\
= \frac{cov(T,T')+cov(E,E')}{D\left[X\right]} \overset{(3.4)}{=} \frac{cov(T,T')}{D\left[X\right]} \overset{(3.6)}{=} \frac{cov(T,T)}{D\left[X\right]} \overset{def}{=} \\
= \frac{\epsilon\left[(X-\epsilon\left[X\right])(X-\epsilon\left[X\right])\right]}{D\left[X\right]} \overset{def}{=} \frac{D\left[T\right]}{D\left[X\right]}.
\end{gathered} \tag{3.9}$$

Samuti märgime, et kuna $T = X - E$, siis kehtib

$$\rho_{XX'} = \frac{D\left[T\right]}{D\left[X\right]} = \frac{D\left[X-E\right]}{D\left[X\right]} = \frac{D\left[X\right]-D\left[E\right]}{D\left[X\right]} = 1 - \frac{D\left[E\right]}{D\left[X\right]}. \tag{3.10}$$

Paneme tähele, kuna $D[X] = D[T] + D[E]$, siis eelneva põhjal $\rho_{XX'} \in [0, 1]$.

Eelneva põhjal on selge, et väide "testi reliaablus on suurem" on samaväärne järgmise kolme väitega:

1. testi korrellatsioon paralleelse testiga on suurem,
2. testi tegeliku tulemuse dispersioon on suurem võrreldes testi vaadeldava tulemuse dispersiooniga,
3. testi mõõtmisvea dispersioon on väiksem võrreldes testi vaadeldava tulemuse dispersiooniga.

Märgime, et klassikalise testiteooria raames defineeritud reliaablus sobib kokku eelmises peatükkis antud mitteformaalse definitsiooniga, kuna küsimustik on isendaga paralleelne testiks võib lugeda ka sama testi uuesti läbiviimise sama vastajate kogumi peal. Paneme tähele, et tegemist on suhteliselt nõrku eeldusi vajava teooriaga, kõigi raskem on praktikas süstemaatiliste vigade puudumist.

Kuna testi tegelik tulemus on suurus, mida me prakikas ei tea ning ka paralleelsete testide läbiviimine ei ole tihti võimalik on kasutusele on üritatud on võimalus testi reliaablust hinnata meie jaoks oluline. Järgnevalt vaatleme, kuidas seda teha.

3.2 Vajalikud taustteadmised reliaabluse hindamiseks

Järgnev käsitlus tugineb Jacksoni ja Anguwamba 1977. aasta artiklile. [8] Olgu meil vastajate populatsioon I, üle mille me vaatleme küsimustiku, milles on k küsimust. Vaatleme seda küsimustiku klassikalise testiteooria raames ning olgu X küsimustiku vaadeldav tulemus, T küsimustiku tegelik tulemus ning E küsimustiku mõõtmisviga. Vaatleme iga küsimust kui ühest küsimusest koosnevat alamküsimustiku ja tähistama fikseeritud küsimuse $i \in \{1, 2, \ldots, k\}$ vaadeltavat tulemust kui X_i, tegeliku tulemust kui T_i ning mõõtmisviga E_i. Seega $X = \sum\limits_{i=0}^{k} X_i$, $T = \sum\limits_{i=0}^{k} T_i$ ja $E = \sum\limits_{i=0}^{k} E_i$. Paneme tähele, et kui eelnevas peatükkis tähistasime alaindeksiga küsimusele vastajat siis edaspidi tähistama sellega kindlat küsimust.

Vaatleme testi küsimuste tulemuste ja mõõtmisvea vektoreid: $(X_1, X_2, X_3, \ldots, X_n)$, $(T_1, T_2, T_3, \ldots, T_n)$, $(E_1, E_2, E_3, \ldots, E_n)$. Tähistame nende vektorite kovariatsioonimaatriksid[3], vastavalt $\Sigma_X, \Sigma_T, \Sigma_E$. Seega,

$$\Sigma_X = \begin{pmatrix} cov\,(X_1, X_1) & cov\,(X_1, X_2) & cov\,(X_1, X_3) & \cdots & cov\,(X_1, X_k) \\ cov\,(X_2, X_1) & cov\,(X_2, X_2) & cov\,(X_2, X_3) & \cdots & cov\,(X_2, X_n) \\ cov\,(X_3, X_1) & cov\,(X_3, X_2) & cov\,(X_3, X_3) & \cdots & cov\,(X_n, X_n) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ cov\,(X_n, X_1) & cov\,(X_n, X_2) & cov\,(X_n, X_3) & \cdots & cov\,(X_n, X_n) \end{pmatrix}.$$

Eelnevalt läbiviidud arutelu (vt. (3.9)) põhjal teame, et $cov(X_i, X_j) = cov(T_i, T_j) + cov(E_j, E_j)$. Seega,

$$\Sigma_X = \Sigma_T + \Sigma_E. \tag{3.11}$$

Lisaks kehtib eelduse (3.4) põhjal saame, et et juhul kui $i \neq j$, siis $cov\,(E_i, E_j) = 0$. Sellest tulenevalt kehtib

$$\Sigma_E = \begin{pmatrix} cov\,(E_1, E_1) & 0 & 0 & \cdots & 0 \\ 0 & cov\,(E_2, E_2) & 0 & \cdots & 0 \\ 0 & 0 & cov\,(E_3, E_3) & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & cov\,(E_n, E_n) \end{pmatrix}. \tag{3.12}$$

Tähistame edaspidi maatriksi Σ_X elemente x_{ij}, maatriksi Σ_T elemente t_{ij} ning maatriksi Σ_E peadiagonaali elemente θ_i. Seega, kui $i \neq j$, siis $t_{ij} = x_{ij}$ ning $t_{ii} = x_{ii} - \theta_i$.

Tuletame meelde, et eelmises peatükkis veendusime (3.10), et testi reliaablus võrdub avaldisega $1 - \frac{D[E]}{D[X]}$.

Veendume, et juhuslike suuruste summa summa dispersioon võrdub liidetavate kovariatsioonimaatriksi elementide summaga ehk kui $X = \sum_{i=1}^{k}$ ja Σ_X on vektori $(X_1, X_2, \ldots, X_K)$ kovariatsioonimaatriks siis

$$D[X] = \sum_{i=1}^{k} \sum_{j=1}^{k} x_{ij}. \tag{3.13}$$

[3]Praktikas ei ole kovariatsioonimaatriksid meil teada, kuid meil on võimalik valimi põhjal saada hinnang vaadeldavate tulemuste kovariatsioonimaatriksile

Eelnevas veendumiseks paneme tähele, et

$$D[X] = D[X_1 + X_2 + \ldots + X_k] \overset{\text{Lause 3.5}}{=}$$
$$= D[X_1] + D[X_2 + X_3 + \ldots + X_k] + 2cov(X_1, X_2 + X_3 \ldots + X_k) \overset{\text{Lause 3.8}}{=}$$
$$= D[X_1] + D[X_2 + X_3 + \ldots + X_k] +$$
$$+2[cov(X_1, X_2) + cov(X_1, X_3) + \ldots + cov(X_1, X_k)].$$

Näeme, et tegemist on rekkurentse võrrandiga. Arvestades, et $cov(X, X) = D[X]$ (vt.(3.9)), näeme, et igale liidetavale eelnevas summas vastab mingite kovariatsioonimaatriksite elementide summa, kusjuures kõik kovariatsioonimaatriksi elemendid kuuluvad täpselt ühte nendest summadest. Kovariatsiooni maatriksi jagunemist illustreerib järgnev tabel, kus sinisega on tähistatud $D[X_1]$, punasega liidetavad, mille summa on võrdne arvuga $2[cov(X_1, X_2)+cov(X_1, X_3)+\ldots+cov(X_1, X_k)]$ ja rohelisega liikmed, mille summast moodustub $D[X_1+X_2+\ldots+X_k]$. Siinkohal meenutame, et kovariatsioon on sümmeetriline ning seega $cov(X_i, X_j) = cov(X_j, X_i)$.

$cov(X_1, X_1)$	$cov(X_1, X_2)$	$cov(X_1, X_3)$	$\ldots$	$cov(X_1, X_k)$
$cov(X_2, X_1)$	$cov(X_2, X_2)$	$cov(X_2, X_3)$	$\ldots$	$cov(X_1, X_k)$
$cov(X_3, X_1)$	$cov(X_3, X_2)$	$cov(X_3, X_3)$	$\ldots$	$cov(X_3, X_k)$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
$cov(X_k, X_1)$	$cov(X_k, X_2)$	$cov(X_k, X_3)$	$\ldots$	$cov(X_k, X_k)$

Lisaks on sellel rekurentses võrandil on lihtne baasjuht, selleks on olukord, kus summa koosneb ainult ühest liidetavast.

Arvestades maatriksi 3.12 ehitust, saame võrduse

$$1 - \frac{D[E]}{D[X]} = 1 - \frac{\sum_i \theta_i}{\sum_i \sum_j x_{ij}}. \tag{3.14}$$

MEELDETULETUSEKS

Definitsioon. Maatriks $C \in Mat_k(\mathbb{R})$ on *mittenegatiivselt määratud* kui iga maatriksi $v \in Mat_{k,1}(\mathbb{R})$ korral $v^T C v \geq 0$.

Veendume järgnevalt, et iga kovariatsioonimaatriks ning järelikult ka Σ_X, Σ_T ja Σ_E on mittenegatiivselt määratud.

MEELDETULETUSEKS

Lause 3.15. Kui X ja Y on juhuslikud suurused ja $\alpha \in \mathbb{R}$, siis

$$cov(X, \alpha Y) = \alpha cov(X, Y)$$

Tõestus.

$$cov(X, \alpha Y) = \epsilon\left[(X - \epsilon[X])(\alpha Y - \epsilon[\alpha Y])\right] \overset{\epsilon \text{ lin.}}{=}$$
$$= \epsilon\left[(X - \epsilon[X])(\alpha Y - \alpha\epsilon[Y])\right] = \epsilon\left[\alpha(X - \epsilon[X])(Y - \epsilon[Y])\right] =$$
$$= \alpha\epsilon\left[(X - \epsilon[X])(Y - \epsilon[Y])\right] = \alpha cov(X, Y)$$

□

Olgu meil suvaliste juhuslike suuruste vektor $X_1, X_2, \ldots, X_n$, kun $n \in \mathbb{N}$ ja olgu Σ_X selle vektori kovariatsioonimaatriks. Olgu meil suvaline k-vektor $v = (v_1, v_2, \ldots, v_n)$. Konstrueerime uue juhuslike suuruste vektori $(X'_1, X'_2, \ldots, X'_n)$, kusjuures $X'_i = v_i X_i$ ning olgu Σ'_X selle vektori kovariatsioonimaatriks. Vaatleme juhusliku suurust $X' = \sum_{i=1}^{n} X'_i$. Kuna eelneva põhjal $D[X'] = \sum_{i=1}^{n}\sum_{j=1}^{n} \Sigma'_{Xij}$ ja definitsiooni põhjal $D[X'] \geq 0$, siis $\sum_{i=1}^{n}\sum_{j=1}^{n} \Sigma'_{Xij} \geq 0$. Kuna Σ'_X on kovariatsioonimaatriks siis,

$$\sum_{i=1}^{n}\sum_{j=1}^{n} \Sigma'_{Xij} = \sum_{i=1}^{n}\sum_{j=1}^{n} cov(v_i X_i, v_j X_j) \overset{\text{Lause 3.15}}{=} \sum_{i=1}^{n}\sum_{j=1}^{n} v_i v_j cov(X_i, X_j). \qquad (3.16)$$

Paneme tähele, et

$$v^T \Sigma_X v =$$
$$= \begin{pmatrix} v_1 cov(X_1, X_1) + v_2 cov(X_1, X_2) + \ldots v_n cov(X_1, X_n) \\ v_1 cov(X_2, X_1) + v_2 cov(X_2, X_2) + \ldots v_n cov(X_2, X_n) \\ \vdots \\ v_1 cov(X_k, X_1) + v_2 cov(X_k, X_2) + \ldots v_n cov(X_n, X_n) \end{pmatrix} v =$$
$$\sum_{i=1}^{n}\sum_{j=1}^{n} v_i v_j cov(X_i, X_j) \overset{(3.16)}{=} \sum_{i=1}^{n}\sum_{j=1}^{n} \Sigma'_{Xij} = D[X']$$

Seega $v^T \Sigma_X v \geq 0$ ning kuna v oli valitud suvaliselt siis on Σ_X mittenegatiivselt määratud. Kuna n ja $X_1, X_2, \ldots X_n$ olid valitud suvaliselt, siis on iga kovariatsioonimaatriks mittenegatiivselt määratud.

Sellega oleme andund reliaablusele matemaatilise definitsiooni ning mõtestanud lahti vajaminevad taustteadmised reliaabluse hindamiseks. Järgnevalt tuletame mõned alumised tõkked reliaablusele.

4 Alumised tõkked reliaablusele

Järgnevalt vaatleme viite alumist tõket reliaablusele ning üritame pakkuda lahendust töö alguses püstitatud probleemile. Vaadeltavatest alumistest tõketest neli - $\lambda_1, \lambda_2, \lambda_3, \lambda_4$; pakkus aastal 1945 välja Louis Guttman [6]. Viienda vaadeldava tõkke pakkusid välja Jackson ja Anguwamba oma 1977 aasta artiklis [8]. Kõik tõkked tuletame tuginedes Jacksoni ja Anguwamba artiklile.

Olgu meil vastajate kogum I, üle mille me vaatleme k küsimusest koosnev küsimustik, mille vaadeldav tulemus on X, tegelik tulemus on T ja mõõtmisviga üle on E. Nummerdame küsimused arvudega 1 kuni k. Vaatleme igat küsimust eraldi alamküsimustikuna, ning olgu X_i küsimuse i vaadeldav tulemus, T_i küsimuse i tegelik tulemus ja E_i küsimuse i mõõtmisviga. Analoogiliselt eelmise peatükiga tähistame vektorite $(X_1, X_2, \dots X_k)$, $(T_1, T_2, \dots, T_k)$ ja $(E_1, E_2, \dots, E_k)$ kovariatsioonimaatrikseid kui $\Sigma_X, \Sigma_T, \Sigma_E \in Mat_k(\mathbb{R})$. Nagu eelmises peatükkis, tähistame ka siin maatriksi Σ_X elemente kui x_{ij}, maatriksi Σ_T elemente kui t_{ij} ning maatriksi Σ_E peadiagonaali elemente θ_i. Edaspidi vaatleme selles peatükkis küsimustiku, mille vaadeldav tulemus on X, reliaabluse alumisi tõkkeid.

4.1 Alumine tõke λ_1

Vaatleme kovariatsioonimaatriksit Σ_T. Eeldame vastuväiteliselt, et maatriksi Σ_T peadiagonaalil leidub element, mis on negatiivne. Olgu selleks elemendiiks t_{ii}. Olgu v vektor, millel on k elementi, kusjuures

$$v_j = \begin{cases} 1, j = 1 \\ 0, j \neq 1 \end{cases} .$$

Paneme tähele, et nüüd $v^T \Sigma_T v = t_{ii} < 0$. Tõepoolest,

$$v^T \Sigma_T v = \begin{pmatrix} t_{i1} & t_{i2} & \dots & t_{ik} \end{pmatrix} v = t_{ii}.$$

Seega ei ole maatriks enam positiivselt määratud, mis on eelmises peatükkis läbiviidud arutelu põhjal vastuolus sellega, et Σ_T on kovariatsioonimaatriks .

Seega iga i peab kehtima $t_{ii} \geq 0$ ning kuna eelmise peatüki põhjal $\Sigma_X = \Sigma_T + \Sigma_E$, siis peab kehtima $\theta_i < x_{ii}$ iga $i, 1 \leq i \leq k$ korral.

Seega ka $\sum\limits_{i=1}^{k} \theta_i \leq \sum\limits_{i=1}^{k} x_{ii}$. Võttes arvesse võrdust (3.14), oleme saanud küsimustiku, mille vaadeldav tulemus on X, reliaablusele alumise tõkke, mida tähistame kui λ_1, kus

$$\lambda_1 = 1 - \frac{\sum_{i=1}^{k} x_{ii}}{\sum_{i=1}^{k}\sum_{j=1}^{k} x_{ij}} \leq 1 - \frac{\sum_{i=1}^{k} \theta_i}{\sum_{i=1}^{k}\sum_{j=1}^{k} x_{ij}} = 1 - \frac{D\left[E\right]}{D\left[X\right]}. \tag{4.1}$$

4.2 Alumine tõke λ_2

Enne järgmise alumise tõke tuletamist, veendume et kehtivad kaks abitulemust.

Olgu meil mitte-negatiivselt määratud sümmeetriline maatriks $C, C \in Mat_n(\mathbb{R})$. Näitame, et sellisel juhul kehtib väide, et iga i, j korral

$$c_{ii}c_{jj} \geq c_{ij}^2.$$

Valime suvaliselt i ja j, nii et $i \neq j, 1 \leq i, j \leq n$ ning $\alpha \in \mathbb{R}$. Olgu meil n-vektor v, kus

$$v_k = \begin{cases} 1, k = i \\ \alpha, k = j \\ 0, k \notin \{i, j\} \end{cases}.$$

Kuna eelduste kohaselt on C mitte-negatiivlet määratud, siis peab kehtima

$$0 \leq v^T C v = \begin{pmatrix} \mathbf{0}^T & 1 & \mathbf{0}'^T & \alpha & \mathbf{0}''^T \end{pmatrix} \begin{pmatrix} c_{11} & \cdots & c_{1n} \\ \vdots & \ddots & \vdots \\ c_{n1} & \cdots & c_{nn} \end{pmatrix} \begin{pmatrix} \mathbf{0} \\ 1 \\ \mathbf{0}' \\ \alpha \\ \mathbf{0}'' \end{pmatrix}, \tag{4.2}$$

kus $\mathbf{0}, \mathbf{0}', \mathbf{0}''$ on null vektorid pikkustega vastavalt $i-1, j-i-1, n-j$.

Arvutame avaldise 4.2 väärtuse:

$$v^T C v = \begin{pmatrix} \mathbf{0}^T & 1 & \mathbf{0}'^T & \alpha & \mathbf{0}''^T \end{pmatrix} \begin{pmatrix} c_{11} & \cdots & c_{1n} \\ \vdots & \ddots & \vdots \\ c_{n1} & \cdots & c_{nn} \end{pmatrix} \begin{pmatrix} \mathbf{0} \\ 1 \\ \mathbf{0}' \\ \alpha \\ \mathbf{0}'' \end{pmatrix} =$$

$$= \begin{pmatrix} \mathbf{0}^T & 1 & \mathbf{0}'^T & \alpha & \mathbf{0}''^T \end{pmatrix} \begin{pmatrix} c_{1i} + \alpha c_{1j} \\ \vdots \\ a_{ni} + \alpha c_{nj} \end{pmatrix} =$$

$$= c_{ii} + \alpha c_{ij} + \alpha c_{ji} + \alpha^2 c_{jj} = c_{ii} + 2\alpha c_{ij} + \alpha^2 c_{jj}.$$

Seega saame, et $0 \leq c_{ii} + 2\alpha c_i j + c_{jj}$. See, et saadud ruutvõrratus on kehtib on samaväärne sellega, et selle ruutvõrrandi diskriminant ei ole nullist suurem. Seega,

$$c_{ij}^2 - c_i c_j \leq 0,$$

milles me soovisimegi veenduda. Eelneva arutelu idee pärineb Ivar Tammeraidi õppikust. [17].

Olgu meil mingid arvud $y_i, 1 \leq i \leq n$. Paneme tähele, et siis kehtib järgvev võrdus

$$\left(\sum_{i=1}^{n} y_i \right)^2 = \sum_{i=1}^{n} \sum_{j=1}^{n} y_i y_j = \sum_{i=1}^{n} y_i^2 + \sum_{i=1}^{n} \left(\sum_{j=1}^{i-1} y_i y_j + \sum_{m=i+1}^{n} y_i y_m \right).$$

Järelikult kehtib ka

$$2(n-1) \left(\sum_{i=1}^{n} y_i \right)^2 = 2(n-1) \sum_{i=1}^{n} y_i^2 + 2(n-1) \sum_{i=1}^{n} \left(\sum_{j=1}^{i-1} y_i y_j + \sum_{m=i+1}^{n} y_i y_m \right).$$

Liidetavad teistmoodi grupeerides saame, et

$$2\,(n-1)\sum_{i=1}^{n} y_i^2 + 2\,(n-1)\sum_{i=1}^{n}\left(\sum_{j=1}^{i-1} y_i y_j + \sum_{m=i+1}^{n} y_i y_m\right) =$$
$$= \left(y_1^2 - 2y_1y_2 + y_2^2\right) + \left(y_1^2 - 2y_1y_3 + y_3^2\right) + \cdots + \left(y_1^2 - 2y_1y_n + y_n^2\right) +$$
$$+ \left(y_2^2 - 2y_2y_1 + y_1^2\right) + + \left(y_2^2 - 2y_2y_3 + y_3^2\right) + \cdots + \left(y_2^2 - 2y_2y_{nn} + y_n^2\right) +$$
$$+ \cdots +$$
$$+ \left(y_n^2 - 2y_ny_1 + y_1^2\right) + \left(y_n^2 - 2y_ny_1 + y_{11}^2\right) + \cdots + \left(y_n^2 - 2y_ny_{n-1} + y_{n-1}^2\right) +$$
$$+2n\sum_{i=1}^{n}\left(\sum_{j=1}^{i-1} y_i y_j + \sum_{m=i+1}^{n} y_i y_m\right) =$$
$$= \sum_{i=1}^{n}\left(\sum_{j=1}^{i-1}(y_i - y_j)^2 + \sum_{m=i+1}^{n}(y_i - y_m)^2\right) + 2n\sum_{i=1}^{n}\left(\sum_{j=1}^{i-1} y_i y_j + \sum_{m=i+1}^{n} y_i y_m\right)$$

Vaatleme jällegi kovariatsiooni maatriksit Σ_E. Märkame, et kuna $x_{ii} = \theta_i + t_{ii}$ iga $1 \leq i \leq k$, siis kehtib järgnev:

$$\sum_{i=1}^{k} \theta_i = \sum_{i=1}^{k} x_{ii} - \sum_{i=1}^{k} t_{ii}$$

.

Märgime, et kuna kovariatsioon on definitsioon põhjal sümmeetriline siis on ka vektori $(Y_1, Y_2, \ldots, Y_n)$ kovariatsioonimaatriks Σ_Y sümmeetriline. Tõepoolest, iga $1 \leq i, j \leq n$ korral,

$$\Sigma_{Y\,ij} = cov(Y_i, Y_j) = cov(Y_j, Y_i) = \Sigma_{Y\,ji}.$$

Eelnevalt käsitletud algebralise samasuse ning kovariatsioonimaatriksite mitte-negatiivselt määratuse ja sümmetrilisuse põhjal kehtib

$$\sum_{i=1}^{k} t_{ii} = \sqrt{\frac{\sum_{i=1}^{k}\left(\sum_{j=1}^{i-1}(t_{ii} - t_{jj})^2 + \sum_{m=i+1}^{k}(t_{ii} - t_{mm})^2\right) + 2k\sum_{i=1}^{k}\left(\sum_{j=1}^{i-1} t_{ii}t_{jj} + \sum_{m=i+1}^{k} t_{ii}t_{mm}\right)}{2\,(k-1)}} \geq$$
$$\geq \sqrt{\frac{k\sum_{i=1}^{k}\left(\sum_{j=1}^{i-1} t_{ii}t_{jj} + \sum_{m=i+1}^{k} t_{ii}t_{mm}\right)}{(k-1)}}$$

Arvestades, et kovariatsioonimaatriks on mitte-negatiivselt määratud ning seda, et kui $i \neq j$ siis $t_{ij} = x_{ij}$, saame eelnevalt tõestatud abitulemuse põhjal väita, et

$$\sum_{i=1}^{k} t_{ii} \geq \sqrt{\frac{k \sum\limits_{i=1}^{k} \left(\sum\limits_{j=1}^{i-1} t_{ii} t_{jj} + \sum\limits_{m=i+1}^{k} t_{ii} t_{mm} \right)}{(k-1)}} \geq \sqrt{\frac{k \sum\limits_{i=1}^{k} \left(\sum\limits_{j=1}^{i-1} x_{ij}^2 + \sum\limits_{m=i+1}^{k} x_{im}^2 \right)}{(k-1)}}$$

Selle taustal saame defineerida alumise tõkke reliaablusele, mida tähistame λ_2:

$$\lambda_2 = 1 - \frac{\sum\limits_{i=1}^{k} x_{ii} - \sqrt{\frac{k \sum_{i=1}^{k} \left(\sum_{j=1}^{i-1} x_{ij}^2 + \sum_{m=i+1}^{k} x_{im}^2 \right)}{(k-1)}}}{\sum\limits_{i=1}^{k} \sum\limits_{j=1}^{k} x_{ij}} \leq 1 - \frac{\sum\limits_{i=1}^{k} x_{ii} - \sum\limits_{i=1}^{k} t_{ii}}{\sum\limits_{i=1}^{k} \sum\limits_{j=1}^{k} x_{ij}} = 1 - \frac{\sum\limits_{i=1}^{k} \theta_i}{\sum\limits_{i=1}^{k} \sum\limits_{j=1}^{k} x_{ij}} = 1 - \frac{D[E]}{D[X]}.$$

Paneme tähele, et

$$\lambda_2 = \lambda_1 + \frac{\sqrt{\frac{k \sum_{i=1}^{k} \left(\sum_{j=1}^{i-1} x_{ij}^2 + \sum_{m=i+1}^{k} x_{im}^2 \right)}{(k-1)}}}{\sum\limits_{i=1}^{k} \sum\limits_{j=1}^{k} x_{ij}}$$

ning seega $\lambda_1 \leq \lambda_2$.

4.3 Alumine tõke λ_3

Vaatleme jällegi kovariatsioonimaatriksit Σ_T. Olgu meil arvud i, j, nii et $1 \leq i, j \leq k$ ning olgu meil k-vektor v, mille elment kohal i on 1 ja element kohal $1 \leq j \leq k, j \neq i$ on -1. Kuna kovariatsioonimaatriks peab olema mittenegatiivselt määratud siis peab kehtima

$$0 \leq v^T \Sigma_T v = v^T \begin{pmatrix} t_{1i} - t_{1j} \\ t_{2i} - t_{2j} \\ \vdots \\ t_{ki} - tkj \end{pmatrix} = t_{ii} + t_{jj} - 2t_{ij},$$

võttes arvesse seda, et kui $i \neq j$, siis $x_{ij} = t_{ij}$ saame, et $t_{ii} + t_{jj} \geq 2x_{ij}$.

Teame, et võimalusi valida i ja j nii, et $i \neq j$ on $k\,(k-1)$. Summeerides kõikide võimalike i ja j valikul saadud võrratused saame, et

$$2\,(k-1)\sum_{i=1}^{k} t_{ii} \geq 2\sum_{i=1}^{k}\left(\sum_{j=1}^{i-1} x_{ij} + \sum_{m=i+1}^{k} x_{im}\right),$$

mis on samaväärne sellega, et

$$\sum_{i=1}^{k} t_{ii} \geq \frac{1}{k-1}\sum_{i=1}^{k}\left(\sum_{j=1}^{i-1} x_{ij} + \sum_{m=i+1}^{k} x_{im}\right).$$

Eelneva põhjal olema oleme saanud järgmise alumise tõkke reliaablusele -

$$\lambda_3 = 1 - \frac{\sum\limits_{i=1}^{k} x_{ii} - \frac{1}{k-1}\sum\limits_{i=1}^{k}\left(\sum\limits_{j=1}^{i-1} x_{ij} + \sum\limits_{m=i+1}^{k} x_{im}\right)}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij}} \leq$$

$$\leq 1 - \frac{\sum\limits_{i=1}^{k} x_{ii} - \sum\limits_{i=1}^{k} t_{ii}}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij}} = 1 - \frac{\sum\limits_{i=1}^{k} \theta_i}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij}} = 1 - \frac{D\,[E]}{D\,[X]}.$$

Tõkke teisendamisel saame, et

$$\lambda_3 = 1 - \frac{\sum\limits_{i=1}^{k} x_{ii} - \frac{1}{k-1}\sum\limits_{i=1}^{k}\left(\sum\limits_{j=1}^{i-1} x_{ij} + \sum\limits_{m=i+1}^{k} x_{im}\right)}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij}} =$$

$$= \frac{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij} - \sum\limits_{i=1}^{k} x_{ii} + \frac{1}{k-1}\sum\limits_{i=1}^{k}\left(\sum\limits_{j=1}^{i-1} x_{ij} + \sum\limits_{m=i+1}^{k} x_{im}\right)}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij}} =$$

$$= \frac{\sum\limits_{i=1}^{k}\left(\sum\limits_{j=1}^{i-1} x_{ij} + \sum\limits_{m=i+1}^{k} x_{im}\right) + \frac{1}{k-1}\sum\limits_{i=1}^{k}\left(\sum\limits_{j=1}^{i-1} x_{ij} + \sum\limits_{m=i+1}^{k} x_{im}\right)}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij}} =$$

$$= \frac{k}{k-1}\left(\frac{\sum\limits_{i=1}^{k}\left(\sum\limits_{j=1}^{i-1} x_{ij} + \sum\limits_{m=i+1}^{k} x_{im}\right)}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij}}\right) = \frac{k}{k-1}\left(1 - \frac{\sum\limits_{i=1}^{k} x_{ii}}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} x_{ij}}\right).$$

Tuletades meelde tõkke λ_1 definitsiooni (4.1) on ilmne, et

$$\lambda_3 = \frac{n\ \lambda_1}{n-1}. \tag{4.3}$$

ja seega $\lambda_1 \leq \lambda_3$. Lisaks on võimalik näidata, et $\lambda_3 \leq \lambda_2$, näiteks [13, 148-149].

Reliaabluse alumine tõke λ_3 on enam tuntud kui Cronbachi α, nimetatud Lee Cronbachi järgi, kes seda oma 1951 aasta artiklis [2] kasutas ning on ilmselt enim kasutatud hinnang reliaablusele. Käesolevas töös jääme siiski selle alumise tõkku nimetamisel λ_3 juurde - nii nimetates tuletatud tõket Louis Guttman oma kuus aastat varem ilmunud artiklis [6].

Siinkohal märgima ka ära, et λ_3 kasutatakse tihti ka hinnanguna testi sisemisele järjepidavusele ning sellega kokku puutudes tuleb kindlasti välja selgitada, mida autor reliaabluse all mõistab.

4.4 Alumine tõke λ_4

Vaatleme kovariatsioonimaatriksit Σ_T. Vaatleme k vektorite hulka $V = \{v : |v_i| = 1\ \forall i, 1 \leq i \leq k\}$. Olgu meil suvaline vektor $v \in V$, kuna Σ_T on mittenegatiivselt määratud, siis teame, et kehtib

$$0 \leq v^T \Sigma_T v,$$

arvestades kovariatsioonimaatriksi Σ_E omadusi saame võrduse (3.11) põhjal

$$\sum_{i=1}^{k} \theta_i = \sum_{i=1} v_i^2 \theta_i = v^T \Sigma_E v \leq v^T \Sigma_X v.$$

Seega, iga $v \in V$ korral saame alumise tõkke reliaablusele. Tõepoolest, (3.14) põhjal iga vektori $v \in V$ korral,

$$1 - \frac{v^T \Sigma_X v}{\sum\limits_{i=1}^{k} \sum\limits_{j=1}^{k} x_{ij}} \leq 1 - \frac{\sum\limits_{i=1}^{k} \theta_i}{\sum\limits_{i=1}^{k} \sum\limits_{j=1}^{k} x_{ij}} = 1 - \frac{D[E]}{D[X]}.$$

Defineerime alumise tõkke λ_4 kui maksimumi kõikidest sellistest tõkketest, seega

$$\lambda_4 = \underset{v \in V}{max} \left(1 - \frac{v^T \Sigma_X v}{\sum\limits_{i=1}^{k} \sum\limits_{j=1}^{k} x_{ij}} \right).$$

4.5 Alumine tõke glb

Paneme tähele, et tänu Σ_E struktuurile (3.12) on tema mittenegatiivselt määratus samaväärne sellega, et $0 \leq \theta_i$ iga $1 \leq i \leq k$ korral.

Tõepoolest, olgu Σ_E mittenegatiivselt määratud ning oletame vastuväiteliselt, et leidub $i, 1 \leq i \leq k$ nii, et $0 > \theta_i$. Olgu v k-vektor, nii et

$$v_j = \begin{cases} 1, j = i \\ 0, j \neq i \end{cases}.$$

Siis $v^T \Sigma_E v = \theta_i < 0$, mis on aga vastuolu sellega, et Σ_E on mittenegatiivselt määratud. Teistpidi, kehtigu $0 \leq \theta_i$ iga $1 \leq i \leq k$ korral. Olgu v suvaline k-vektor. Siis $v^T \Sigma_E v = \sum_{i=1}^{k} v_i^2 \theta_i \geq 0$. Kuna v oli suvaline, siis on Σ_E vastavalt definitsioonile mittenegatiivselt määratud.

Üritame nüüd leida vea suurimat võimaliku dispersiooni, mis on (3.10) põhjal samaväärne summaga $\sum_{i=1}^{k} \theta_i$, arvestades eelnevalt kirjeldatud piiranguid. Saame selle panna kirja järgneva optimiseerimisülesandena:

$$\begin{gathered} max \sum_i \theta_i \\ \theta_i > 0 \\ \Sigma_X = \Sigma_T + \Sigma_E \\ \Sigma_T \succeq 0, \end{gathered} \tag{4.4}$$

kus kirjapilt $\Sigma_T \succeq 0$ tähistab tingimust "Σ_T on mittenegatiivselt määratud".

Olgu z eelneva optimiseerimisülesande lahend Σ_X korral. Tähistame tähekombinatsiooniga *glb*, mis tuleneb fraasist *greatest lower bound*, lahendi z abil saadud alumise tõkke reliaablusele, kus

$$glb = 1 - \frac{z}{\sum_{i=1}^{k} \sum_{j=1}^{k} x_{ij}}.$$

Panemet tähele, et kuna z on maksimaalne vea dispersioon fikseeritud Σ_X korral, siis on alumine tõke *glb* minimaalne võimalik reliaablus. Siit aga saame, et iga teine reliaabluse alumine tõke peab olema väiksem võrdne tõkega *glb*. Seega on *glb* suurim võimalik alumine tõke.

4.6 Hinnangute kasutatavus praktikas

Püstitasime töö alguses probleemi - kas võimalik leida reliaablusele parem hinnang kui seda on λ_3? Käsitletud hinnangutest on nii *glb* kui λ_2 reliaabluse alumised tõkked ning samas vähemalt sama suured kui λ_3, seega ka paremad hinnangud reliaablusele kui seda on λ_3. Samuti on raske leida empiirilist näidet, kus λ_4 ei ole tingimata suurem oleks väiksem kui λ_3.

Paneme tähele, et λ_3 leidmine on väga lihtne ning eelmise sajandi keskel, olukorras kus arvutuslik võimsus oli tagashoidlik, oli tegemist olulise eelisega. Tänapäeval on λ_3 lihtsus pea olematu eelis, arvestades, et ka väga suurte küsimustike puhul ei valmista paremate hinnangute leidmine optimiseeritud programmi korral probleeme.

Lisas B ära toodud näidete põhjal näeme, et praktikas võivad hinnangud olla väga erinevad, näiteks joonisel 13 kujutatud kovariatsoonimaatriksi korral erineb on *glb* võrreldes hinnanguga λ_3 oluliselt suurem, vastavalt $0,77$ ja $0,43$. Joonisel 13 on aga näha, et isegi juhul, kui λ_3 on suur, annavad nii glb, λ_4 kui ka λ_3 suuremaid hinnanguid.

Seega, kui küsimustiku analüüsia mõtestab küsimustiku klassikalise testiteooria raamistikus, siis ei näe autor mingit põhjust, miks peaks kasutama reliaabluse hindamiseks λ_3 ning soovitab eelistada teisi, kõrgemaid, hinnaguid. Autor märgib siinkohal, et tegemist tundub olevat valdkonna ekpertide seas levinud arvamusega. [13] [15] [3]

Mainime siinkohal ära, et hinnangud *glb* ja λ_4 võivad teatud tingimustel olla nihkega, probleem mis esineb praktikas, kui me kasutame kovariatsiooni maatriksi asemel tema valimi põhjal saadud hinnangut. Tõkke *glb* korral vaata näiteks [**?**], λ_4 puhul [**?**].

5 Intervallskaal alternatiivne tõlgendamine

Läheneme nüüd reliaabluse hinnangu parandamisele teisest suunast ning vaatleme, millist mõju avaldab hinnangule λ_3 vastuste teistsugune tõlgendamine intervallskaalal.

5.1 Vastuste tõlgendamine intervallskaalal

Käesoleva töö sissejuhatuses kirjeldasime viisi, kuidas vaikimisi paigutakse intervallskaalal erinevaid vastuseid Likerti skaalalt. Märgime, et selline tõlgendus ei ole põhjendatud - meil ei ole mingit teoreetilist põhjust eeldada, et kõik vastused on üksteisest sama "kaugel".

Sellest tähelepanekust lähtub järgmine küsimus - kas on võimalik leida parem vastuste paigutus intervallskaalal kui vaikimisi meetod? Vaatleme kahte näidet:

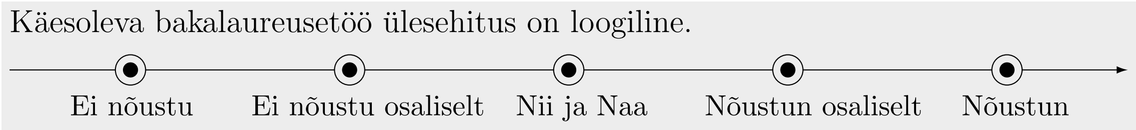

Joonis 6: Näide, kuidas hinnangud skaalal vaikimisi meetodit kasutades paigutuvad

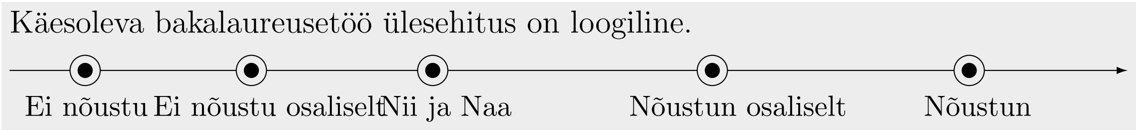

Joonis 7: Näide hinnangute alternatiivsest paiknemisest skaalal

Kui me tahame välja pakkuda alternatiive vaikimisi tõlgendusele, peab meil olema mingi karakteristik, mille alusel tõlgendust hinnata. Pakume välja järgmise idee : üritame leida hinnangute paiknemist skaalal nii, et küsimustiku reliaablus oleks võimalikult suur. Seame endale loomuliku piirangu - vastuste esialgne järjestus ei tohi muutuda.

5.2 Reliaabluse hindamine

Kuna küsimustiku reliaabluse leidmin ei ole praktiliselt võimalik, siis kasutame selle lähendusena eelmises peatükkis käsitletud alumisi tõkkeid. On selge, et parimi tulemuse annab võimalikult täpse alumise tõkku kasutamine. Kuid kuna sobiva tõlgenduse leidmine taandub optimiseerimisülesandeks, siis kasutame siinkohal ühte konservatiivsemat alumist tõket, λ_3 - selle arvutamise lihtsus, mis ei omanud fikseeritud tõlgenduse korral tänapäevase aruvutusvõimuse juures erilist tähtsust osutub siin oluliseks eeliseks.

5.3 Lähenemise korrektsus

Lugejal võib siinkohal tekkida kaks küsimust lähenemise korrektuse kohta.

Esiteks, kas selline lähenemine tagab meile kõrgema küsimustiku kõrgema reliaabluse? Vastus sellele küsimusele on kahjuks eitav - tõepoolest, on võimalik, et me saame teistsuguse tõlgendusega küsimustiku, mille reliaabluse alumine tõke on suurem kui vaikimisi tõlgendusega küsimustiku puhul kuid mille reliaablus on samal ajal madalam. Kuna aga meil ei ole võimalik reliaablust täpselt mõõta, ei ole meil ka otsest põhjust uskuda, et ühe tõlgendusega saadud reliaablus on parem kui teisega.

Küll aga kerkib siinkohal esile praktilisem probleem seoses λ_3 kasutamisega reliaabluse hindamisel. Nimelt võib leida aset olukord, kus meie poolt pakutava tõlgenduse korral on λ_3 kõrgem, kui vaikimisi tõlgenduse puhul kuid mõni tihedam alumine tõke on madalam. Illustreerime seda olukorda näitega.

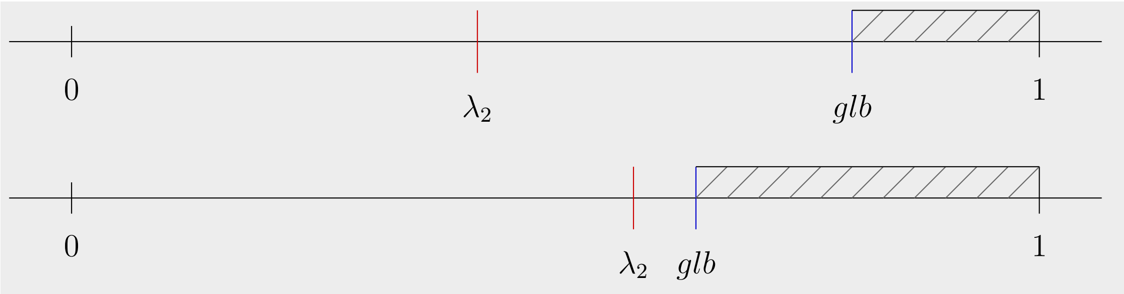

Joonis 8: Olukord, kus alternatiivne tõlgendus suurendab alumist tõket λ_3 ja vähendab alumist tõket *glb*

Joonisel kujutatud olukord on kindlasti ebasoovitav. Lihtsam võimalik lahendus on uue tõlgenduse korral leida teised alumised tõkked ning juhul, kui parim alumine tõke vaikimisi tõlgendusele on kõrgem kui leitud tõlgendusele, siis jääda vaikimisi tõlgenduse juurde. Keerukam lahendus oleks kasutada mõnda optimiseerimisel mõnda paremat alumist tõket - selle lähenemise puuduseks on aga kaasnev vajadus lahendada keerukam optimiseerimisülesanne.

Teiseks, kuidas mõjutab vastuste tavapärasest erinev tõlgendus testi valiidsust? Sellele küsimusele märgime ära, et kuigi vaikimisi definitsioon on laialdaselt levinud, on ta siiski täiesti arbitraarne ning seega samaväärne meie poolt pakutud tõlgendusega - meil ei ole mingit kindlati põhjust uskuda, et ühe tõlgenduse korral on valiidsus parem kui teise korral. Ühelt poolt on selline vastus mitterahuldav - meie poolt pakutud lahendus ei pruugi olla parem kui olemasolev. Teiselt poolt - vaikimisi kasutatav tõlgendus ei pruugi olla parem kui meie poolt pakutav.

Meie poolt paktuava tõlgenduse väikese eelisena võib siiski ära tuua järgneva. Kuna enamike valiidsuse definitsioonide korral on valiidsus ülevalt tõkesatud mingi funktsiooniga reliaablusest (kõige levinuma definitsiooni korral on tõkkeks reliaabluse positiivne ruutjuur), siis reliaabluse alumise tõkke abil saame me midagi öelda valiidsuse kõige väiksema võimaliku ülemise tõkke kohta. Paneme tähele, et kuna me teame ainult reliaabluse alumist tõket ja mitte reliaablust ennast, ei ole meil mingit põhjust väita, et vähim võimalik ülemine tõke ka on küsimustiku valiidsuse ülemiseks tõkkeks.

5.4 Alternatiivse tõlgenduse matemaatiline sõnastus

Olgu meil populatsioon I ning k küsimusega küsimustik, kus iga küsimuse kohta palutakse hinnangut l-palli Likerti skaalal. Nummerdama küsimused naturaalarvudega 1 kuna k Olgu meil juhuslikud suurused $K_1, K_2, ..., K_k$, mille määramispiirkonnaks on kõik erinevad võimalikud vastuste kombinatsioonid küsimustikule ning muutumispiirkonnaks on hulk $\{1, 2, \ldots, l\}$ ning tõlgendame juhusliku suurust kui küsimusele k antud vastuse tõlgendust vaikimisi kasutataval intervallskaalal. Toome sisse ka tähistused $p_{i\alpha}, i \in \{1, 2, ..., n\}, \alpha \in \{1, 2, \ldots, l\}$, kus $p_{i\alpha}$ tähistab põhjal tõenäosusust, et juhusliku suuruse K_i väärtus on α.

Tuletame meelde λ_3 definitsiooni üle vektori $(K_1, K_2, \ldots, K_k)$ kovariatsioonimaatriksi Σ_K:

$$\lambda_3 = (\frac{k}{k-1})(1 - \frac{\sum\limits_{i=1}^{k} \Sigma_{Kii}}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} \Sigma_{Kij}})$$

Paneme tähele, et võttes arvesse seda, et $\Sigma_{Kij} = cov(K_i, K_j)$ ja definitsiooni järgi $cov(X, X) = \epsilon\left[(X - \epsilon\left[X\right])(X - \epsilon\left[X\right])\right]$, saame, et

$$\lambda_3 = (\frac{k}{k-1})(1 - \frac{\sum\limits_{i=1}^{k} \Sigma_{Kii}}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} \Sigma_{Kij}}) = \frac{k}{k-1}\left(1 - \frac{\sum\limits_{1=0}^{k} D(K_i)}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} cov(K_i, K_j)}\right)$$

Soovime leida sellise viisi vastute tõlgendamiseks, et λ_3 oleks maksimaalne. Kujutame juhuslikud suurused $K_1, K_2, \ldots, K_n$ juhuslikeks suurusteks $M_1, M_2, M_2, \ldots, M_n$, kusjuures juhusliku suuruse M_i määramispiirkond ühtib suuruse K_i määramispiirkonnaga ning M_i saab väärtusi hulgast $M_i = \{\mu_{1i}, \mu_{2i}, \ldots, \mu_{li}\}$ $i \in 1, 2, ...n$. Lisaks kehtigu järgnevad kitsendused:

$$\mu_{i1} < \mu_{i2} < \ldots < \mu_{il},$$

$$K_i(\omega) = j \implies M_i(\omega) = \mu_{ij}, \forall j, 1 \leq j \leq l.$$

Siinkohal märgime, et hinnangute tõlgenduste juures ei huvita meid mitte absoluutne, vaid suhteline paigutus. Seda arvesse võttes lisame järgnevad normaliseerivad kitsendused:

$$E(L_i) = \sum_{j=1}^{l} p_{ij}\mu_{ij} = 0, \tag{5.1}$$

$$D(L_i) = \sum_{j=1}^{l} p_{ij}(\mu_{ij} - E(L_i))^2 = \sum_{j=1}^{l} p_{ij}\mu_{ij}^2 = 1. \tag{5.2}$$

Paneme tähele, et selliste piirangute korral esitub λ_3 lihtsamal kujul. Tõepoolest
,

$$\lambda_3 = \frac{k}{k-1}\left(1 - \frac{\sum\limits_{1=0}^{k} D(M_i)}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} cov(M_i, M_j)}\right) = \frac{k}{k-1}\left(1 - \frac{k}{\sum\limits_{i=1}^{k}\sum\limits_{j=1}^{k} cov(M_i, M_j)}\right).$$

Siit näeme, et sellisel juhul taandub λ_3 maksimeerimine avaldise $\sum\limits_{i=0}^{n}\sum\limits_{j=0}^{n} COV(M_i, M_j)$ maksimeerimisele.

Käesoleva bakalaureusetöö ülesehitus on loogiline.

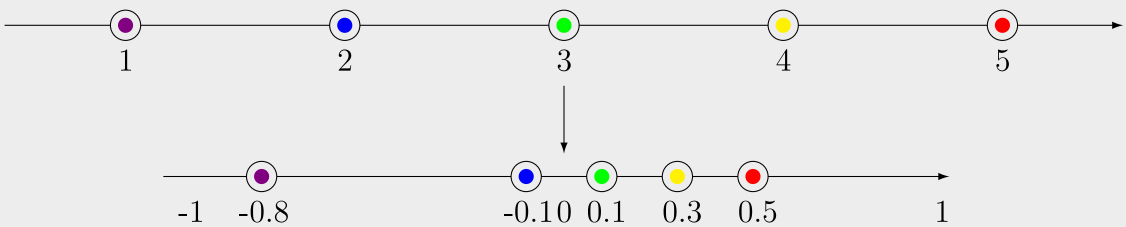

Joonis 9: Üks võimalik näide sellest, kuidas suhestudad hulgad $ran(K_i)$ ja $ran(M_i)$

Olgu meil tõenäosuste maatriks P, kusjuures

$$P = \begin{pmatrix} p_{(11)(11)} & p_{(11)(12)} & \cdots & p_{(11)(1l)} & p_{(11)(21)} & p_{(11)(22)} & \cdots & p_{(11)(kl)} \\ p_{(12)(11)} & p_{(12)(12)} & \cdots & p_{(12)(1l)} & p_{(12)(21)} & p_{(12)(22)} & \cdots & p_{(12)(kl)} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ p_{(kl)(11)} & p_{(kl)(12)} & \cdots & p_{(kl)(1l)} & p_{(kl)(21)} & p_{(kl)(22)} & \cdots & p_{(kl)(kl)} \end{pmatrix}$$

kus $p_{(i\alpha)(j\beta)}, i, j \in \{1, 2, ..., k\}, \alpha, \beta \in \{1, 2, \ldots, l\}$ tähistab tõenäosust, et juhuslik suurus K_i saab väärtuse α ja juhuslik suurus K_j saab väärtuse β.

Defineerime vektori x, nii et

$$x = (\mu_{11}, \mu_{12}, \ldots, \mu_{1l}, \mu_{21}, \mu_{22}, \ldots, \mu_{nl})$$

- - - SIIA MAANI REFAKTOREERITUD! EDASI OMAL VASTUTUSEL! - - - -

Siis $xPx^T = \sum_{i=1}^{n} \sum_{j=1}^{n} cov(M_i, M_j)$. Veendume selles:

$$xPx^T = \begin{pmatrix} \mu_{11} & \mu_{12} & \cdots & \mu_{kl} \end{pmatrix} \begin{pmatrix} p_{(11)(11)} & p_{(11)(12)} & \cdots & p_{(11)(kl)} \\ p_{(12)(11)} & p_{(12)(12)} & \cdots & p_{(12)(kl)} \\ \vdots & \vdots & \ddots & \vdots \\ p_{(kl)(11)} & p_{(kl)(12)} & \cdots & p_{(kl)(kl)} \end{pmatrix} \begin{pmatrix} \mu_{11} \\ \mu_{12} \\ \vdots \\ \mu_{kl} \end{pmatrix} =$$

$$= \begin{pmatrix} \sum_{j=1}^{n} \sum_{r=1}^{l} \lambda_{jr} p_{(jr)(11)} & \sum_{j=1}^{n} \sum_{r=1}^{l} \lambda_{jr} p_{(jr)(12)} & \cdots & \sum_{j=1}^{n} \sum_{r=1}^{l} \lambda_{jr} p_{(jr)(nl)} \end{pmatrix} \begin{pmatrix} \mu_{11} \\ \mu_{12} \\ \vdots \\ \mu_{nl} \end{pmatrix} =$$

$$= \sum_{j=1}^{n} \sum_{r=1}^{l} \lambda_{jr} p_{(jr)(11)} + \sum_{j=1}^{n} \sum_{r=1}^{l} \lambda_{jr} p_{(jr)(12)} + \cdots + \sum_{j=1}^{n} \sum_{r=1}^{l} \lambda_{jr} p_{(jr)(nl)} =$$

$$= \sum_{i=1}^{n} \sum_{k=1}^{l} \sum_{j=1}^{n} \sum_{r=1}^{l} \lambda_{jr} p_{(jr)(ik)} \lambda_{ik} = \sum_{i=1}^{n} \sum_{j=1}^{n} \sum_{k=1}^{l} \sum_{r=1}^{l} \lambda_{jr} p_{(jr)(ik)} \lambda_{ik} = \sum_{i=1}^{n} \sum_{j=1}^{n} E(M_i M_j) =$$

$$\underset{(5.1)}{=} \sum_{i=1}^{n} \sum_{j=1}^{n} E(M_i M_j) - E(M_i)E(M_j) = \sum_{i=1}^{n} \sum_{j=1}^{n} cov(M_i, M_j)$$

Eelneva põhjal piisab meile,arvestades eelnevalt äratoodud piiranguid L_i keskväärtusele ja dispersioonile, suurima võimaliku λ_3 leidmiseks ruutvõrrandi xPx^T maksimeerimisest. Seega saame püstitada järgneva optimeerimisprobleemi, mille lahendus annab meile otsitavad tõlgendused.

$$
\begin{gathered}
min\ x^T(-P)x \\
R_i^T x = 0, i \in 1, 2, \ldots, k \\
R_i = (\underbrace{0, 0, \ldots 0, 0}_{(i-1)*l} p_{i1}, p_{i2}, p_{i3}, p_{i4}, \ldots, p_{il}, \underbrace{0, 0, \ldots, 0, 0}_{(n-i)*l}) \\
x^T Q_i x = 1, i \in \{1, 2, ..., k\},\ Q_i = \begin{pmatrix} q_{11} & 0 & \cdots & 0 \\ 0 & q_{12} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & q_{kl} \end{pmatrix} \\
q_{jk} = \begin{cases} 0 & j \neq i \\ p_{ik} & i = j \end{cases}
\end{gathered} \tag{5.3}
$$

6 Lahenduse idee

Kas probleem on SDP tüüpi või SDP? Miidlale kirjutan vast nendes küsimustes. Mingi sissejuhatav jutt QCQP ja SDP kohta, kas algusessse taust peatükki või pigem teksti sisse ? Püstitatud optimeerimis probleemi lahendamiseks teisendame probleemi *semidefinite programming(SDP)* tüüpi optimeerimisülesandeks ning seejärel lahendame saadud ülesande.

7 Teisendus *QCQP* tüüpi ülesandelt *SDP* tüüpi ülesandele

Esiteks teisendame saadud $QCQP$ standartkujule. Siia vaja selgitusi, mis ja kuidas

$$
\begin{gathered}
min\ \ -\theta \\
x^T P x - \theta \leq 0
\end{gathered}
$$

$$
\begin{aligned}
R_i^T x \le 0, i \in 1, 2, ..., n \\
-R_i^T x \le 0, i \in 1, 2, ..., n \\
R_i = (\underbrace{0, 0, ...0, 0}_{(i-1)*5} p_i a, p_i b, p_i c, p_i d, p_i e, \underbrace{0, 0, ..., 0, 0}_{(n-i)*5}) \qquad (7.1) \\
x^T P_i x - 1 \le 0, i \in \{1, 2, ..., n\} \\
-(x^T P_i x - 1) \le 0, i \in \{1, 2, ..., n\} \\
P_i = \begin{pmatrix} p_{ja} & 0 & \cdots & 0 \\ 0 & p_{jb} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & p_{je} \end{pmatrix} \\
p_j \alpha = \begin{cases} 0 & j \ne i \\ p_i \alpha & i = j \end{cases}, \alpha \in \{a, b, c, d, e\}
\end{aligned}
$$

[?, 116]

Paneme tähele, et kuna maatriksid P, R_i, P_i on sümmeetrilised ja mittenegatiivselt määratud, siis leiduvad maatrikisd Q, S_i, Q_i nii, et $P = QQ^T, R_i = S_i S_i^T, P_i = Q_i Q_i^T$. Nende maatriksite leidmiseks saab kasutada Cholesky lahutust. [17, 151] raamatus juhj positiivselt määratud maatriksi korral, mittenegatiivselt määratud maatriksi korral sellied maatriksid leiduvad, kuid ei ole alati üheselt määratud.

Olgu A mittenegatiivselt määratud maatriks, olgu $A = LL^T$.Märkame, et kehtib järgnev:

$$
x^T A x \le b^T x + c \iff \begin{pmatrix} I_k & L^T x \\ x^T L & b^T x + c \end{pmatrix} \succeq 0 \qquad (7.2)
$$

[?, 31]

Seega saame anda oma optimeerimisprobleemile järgneva kuju:

$$
\begin{aligned}
min \ -\theta \\
\begin{pmatrix} I_k & Q^T x \\ x^T Q & \theta \end{pmatrix} \succeq 0 \\
R_i^T x \le 0, i \in 1, 2, ..., n \\
-R_i^T x \le 0, i \in 1, 2, ..., n \\
R_i = (\underbrace{0, 0, ...0, 0}_{(i-1)*5} p_i a, p_i b, p_i c, p_i d, p_i e, \underbrace{0, 0, ..., 0, 0}_{(n-i)*5}) \qquad (7.3)
\end{aligned}
$$

$$\begin{pmatrix} I_k & Q_i^T x \\ t^T & 1 \end{pmatrix} \succeq 0$$

$$\begin{pmatrix} I_k & Q_i^T x \\ -x^T Q_i & -1 \end{pmatrix} \succeq 0$$

8 Programmiteek

Põhjendan siin ka lühidalt Pythoni eeliseid teegi realiseerimisel, alternatiividega (näiteks Java või MATLAB) võrreldes:

1. Python on hetkel keel, millega programeerimisalased õppingud tavaliselt algavad. Näiteks Tartu Ülikoolis õpetatakse programeerimist keeles Python nii matemaatika-informaatika teaduskonnale suunatud aines kui ka teistele huvilistele suunatud aines "Programeerimise alused", mida 2013/2014 aasta kevadel kuulas 150 inimest. Autor loodab, et nende seas on ka mõned psühholoogia tudengid.

2. Pythonil on läbi NumPy ja SciPy teekide väga hea arvutuslik tugi soovitud hinnangute implementeerimiseks.

3. Pythoni teek on väga lihte integreerida mõne veebiraamistikuga, mis võiks olla loodava teegi üks rakenduskohti.

4. Python on vabavara ning kõigile tasuta kasutatav.

Meetoditest, mis leiavad λ_1, λ_2, λ_3 ja λ_4 on implementeeritud nii programeerimiskeeles Python 2 kui ka programeerimiskeeles Python 3. Klass, mille abil saab leida glb, on implementeeritud sõltuvate teekide piirangute tõttu ainult programeerimiskeeles Python 2. Kasutatud on teeke SciPy [10] ja CVXPY [4]. Programmiteek on kättesaadav aadressil : SIIA AADRESS

Lisas C on ära toodud programmiteegi implementatsioon programeerimiskeeles Python 2.

Viited

[1] Lee J. Cronbach. Test "Reliability": Its Meaning and Determination. *Psychometrika*, 12(1):1–16, 1947.

[2] Lee J. Cronbach. Coefficient Alpha and the Internal Structure of Tests. 16(3):297–330, 1951.

[3] Lee J. Cronbach and Richard J. Shavelson. My Current Thoughts on Coefficient Alpha and Successor Procedures. *Educational and Psychological Measurement*, 64(3):391–418, June 2004.

[4] S. Diamond, S; Chu, E; Boyd. CVXPY: A Python-Embedded Modeling Language for Convex Optimization, 2014.

[5] Diane R. Edmondson. Likert Scales: A History. In *Conference on Historical Analysis & Research in Marketing Proceedings*, 2005.

[6] Louis Guttman. A Basis for Analyzing Test-Retest Reliability. *Psychometrika*, 10(4):255–282, 1945.

[7] Robin K. Henson. Understanding Internal Consistency Reliability Estimates: A Conceptual Primer on Coefficient Alpha. *Measurement & Evaluation in Counseling & Development*, 34(3):177, 2001.

[8] Paul H Jackson and Christian C. Agunwamba. Lower Bounds for the Reliability of the Total Score on a Test Composed of Non-Homogeneous Items: I: Algebraic Lower Bounds. *Psychometrika*, 42(2):567–578, 1977.

[9] Susan Jamieson. Likert scales: how to (ab)use them. *Medical education*, 38(12):1217–8, December 2004.

[10] Eric Jones, Travis Oliphant, and Pearu Peterson. SciPy: Open Source Scientific Tools for Python.

[11] F.M. Lord and M.R Novick. *Statistical theories of mental test scores.* 1968.

[12] Melvin R. Novick. The axioms and principal results of classical test theory. *Journal of Mathematical Psychology*, 3(1):1–18, February 1966.

[13] William Revelle and Richard E. Zinbarg. Coefficients Alpha, Beta, Omega, and the glb: Comments on Sijtsma. *Psychometrika*, 74(1):145–154, December 2008.

[14] Klaas Sijtsma. On the use, the misuse, and the very limited usefulness of cronbach's alpha. *Psychometrika*, 74(1):107–120, 2009.

[15] Klaas Sijtsma. Reliability Beyond Theory and Into Practice. *Psychometrika*, 74(1):169–173, 2009.

[16] Nicholas Smith. Example of Likert Scale. http://en.wikipedia.org/wiki/File:Example_Likert_Scale.svg.

[17] Ivar Tammeraid. *Lineaaralgebra rakendused*. TTÜ Kirjastus, Tallinn, 1999.

[18] UT. Õisi tagasiside. http://is.ut.ee.

[19] D. W. Zimmerman. Probability spaces, hilbert spaces, and the axioms of test theory. 40(3):395–412, 1975.

Lisa

A Näited küsimustikust Likerti skaalal

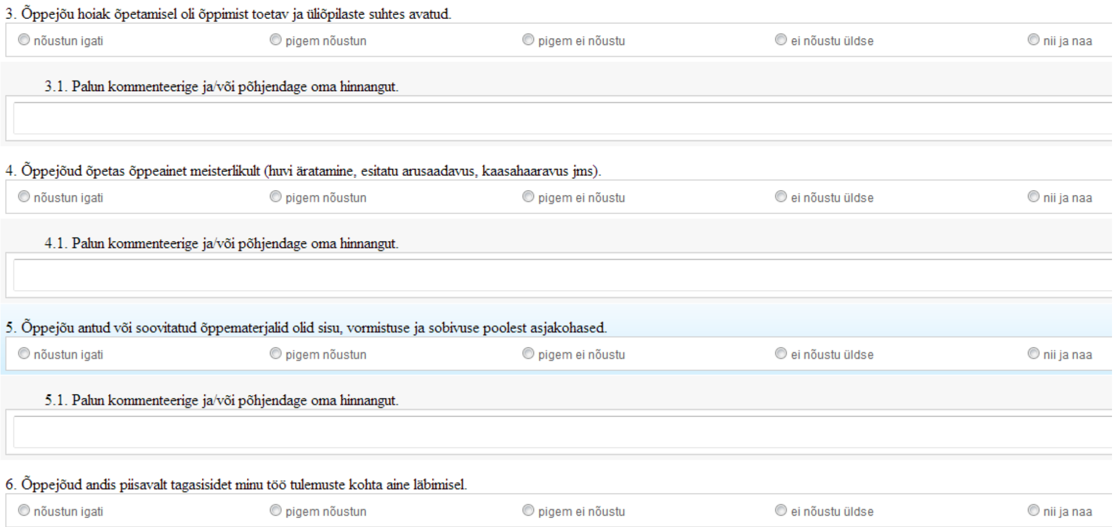

3. Õppejõu hoiak õpetamisel oli õppimist toetav ja üliõpilaste suhtes avatud.

nõustun igati | pigem nõustun | pigem ei nõustu | ei nõustu üldse | nii ja naa

3.1. Palun kommenteerige ja/või põhjendage oma hinnangut.

4. Õppejõud õpetas õppeainet meisterlikult (huvi äratamine, esitatu arusaadavus, kaasahaaravus jms).

nõustun igati | pigem nõustun | pigem ei nõustu | ei nõustu üldse | nii ja naa

4.1. Palun kommenteerige ja/või põhjendage oma hinnangut.

5. Õppejõu antud või soovitatud õppematerjalid olid sisu, vormistuse ja sobivuse poolest asjakohased.

nõustun igati | pigem nõustun | pigem ei nõustu | ei nõustu üldse | nii ja naa

5.1. Palun kommenteerige ja/või põhjendage oma hinnangut.

6. Õppejõud andis piisavalt tagasisidet minu töö tulemuste kohta aine läbimisel.

nõustun igati | pigem nõustun | pigem ei nõustu | ei nõustu üldse | nii ja naa

Joonis 10: Näide Tartu Ülikooli õppeinfo süsteemi tagasiside ankeedist, kus rakendatakse Likerti skaalat [18]

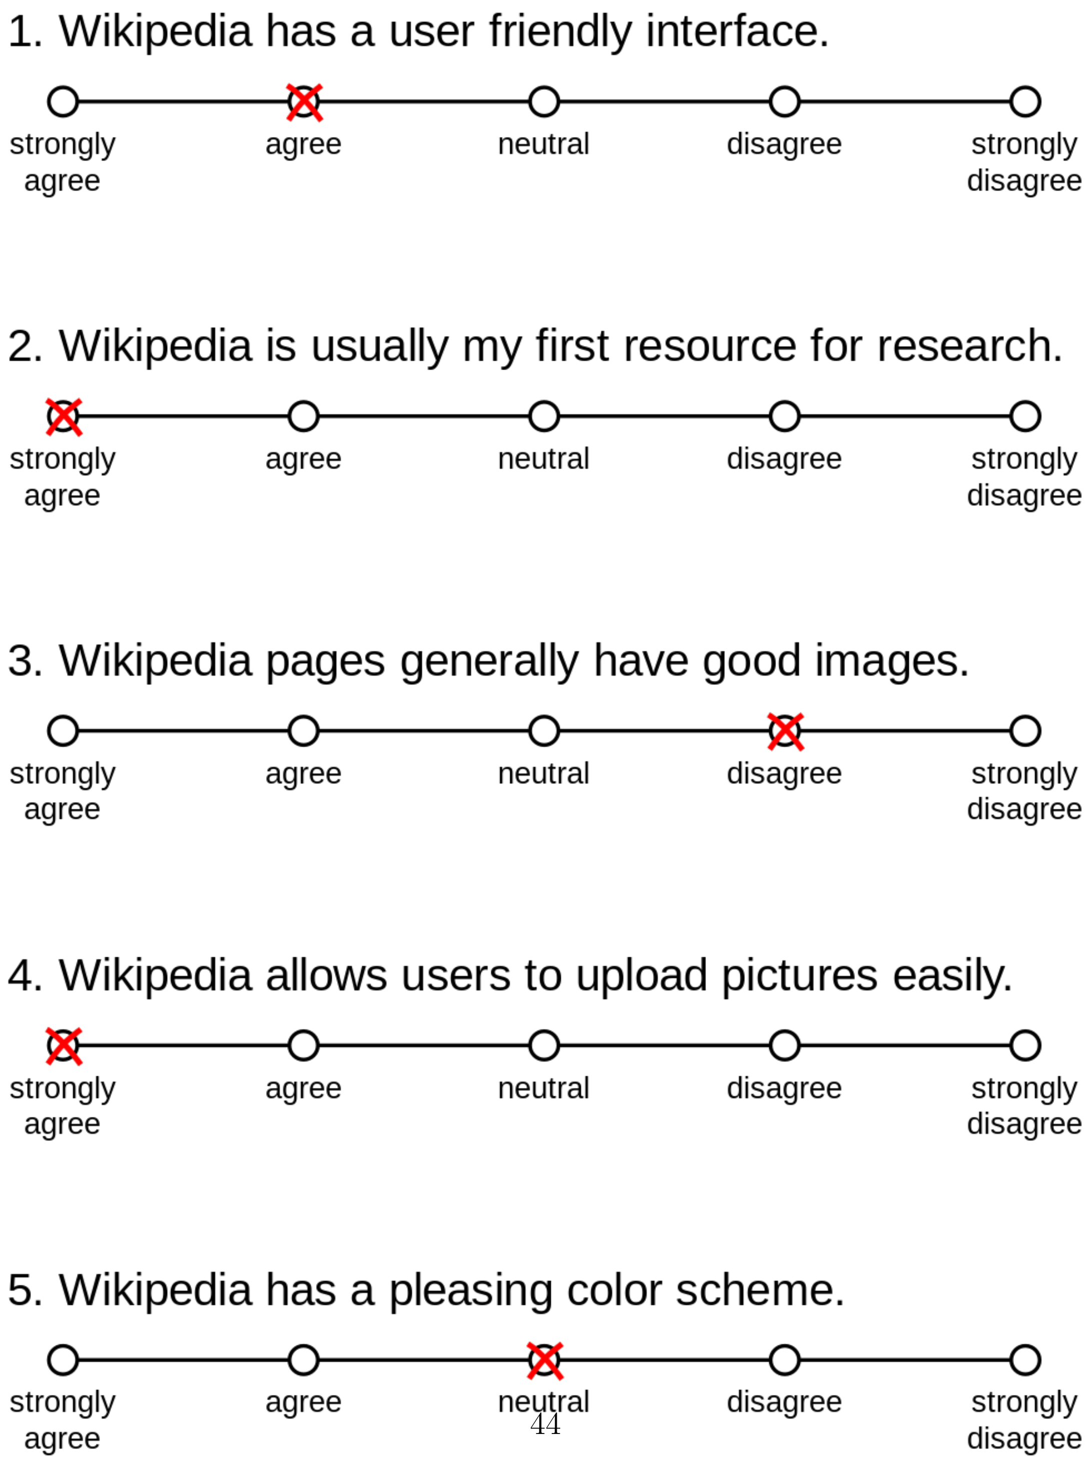

Joonis 11: Näide küsimustikust, kus on rakendatud Likerti skaalat; küsimused on paigutatud nende järjestikulisuse rõhutamiseks teljele [16]

B Empiirilised näited

Järgnevad kovariatsioonimaatriksid on leitud ühe psühholoogilise küsimustiku andmete põhjal, jagadas küsimustiku alamküsimustikeks.

Kovariatsioonimaatriks

3.00	1.52	1.73	1.21	0.69	1.40	-0.53	-0.64	-0.75	-0.56	-0.57	-0.83
1.52	3.25	1.37	0.70	0.78	1.01	-0.31	-0.21	-0.17	-0.39	-0.29	-0.65
1.73	1.37	3.25	1.43	0.85	1.62	-0.71	-0.77	-0.94	-0.98	-0.65	-1.20
1.21	0.70	1.43	2.79	0.16	1.00	-1.03	-1.23	-0.98	-0.87	-0.82	-0.85
0.69	0.78	0.85	0.16	2.67	0.82	-0.11	0.20	-0.10	0.10	0.40	-0.09
1.40	1.01	1.62	1.00	0.82	2.37	-0.52	-0.48	-0.84	-0.55	-0.37	-0.73
-0.53	-0.31	-0.71	-1.03	-0.11	-0.52	1.59	1.25	0.52	0.87	0.65	0.93
-0.64	-0.21	-0.77	-1.23	0.20	-0.48	1.25	2.38	0.77	1.12	0.92	1.02
-0.75	-0.17	-0.94	-0.98	-0.10	-0.84	0.52	0.77	2.30	0.81	0.75	0.68
-0.56	-0.39	-0.98	-0.87	0.10	-0.55	0.87	1.12	0.81	2.14	1.00	1.25
-0.57	-0.29	-0.65	-0.82	0.40	-0.37	0.65	0.92	0.75	1.00	2.09	0.69
-0.83	-0.65	-1.20	-0.85	-0.09	-0.73	0.93	1.02	0.68	1.25	0.69	2.03

Hinnang	λ_1	λ_2	λ_3	λ_4	glb
Väärtus	0.39	0.60	0.43	0.73	0.77

Joonis 12: Valimi kovariatsioonimaatriks koos reliaabluse hinnangutega

Kovariatsioonimaatriks

Variable	1	2	3	4	5	6	7	8	9	10	11	12
	3.00	1.52	1.73	1.21	0.69	1.40	1.39	0.90	1.27	1.15	0.58	0.83
	1.52	3.25	1.37	0.70	0.78	1.01	1.10	1.73	0.94	0.85	0.56	0.70
	1.73	1.37	3.25	1.43	0.85	1.62	1.19	0.61	1.85	1.28	0.61	0.85
	1.21	0.70	1.43	2.79	0.16	1.00	0.64	0.26	0.93	1.49	0.14	0.53
	0.69	0.78	0.85	0.16	2.67	0.82	0.77	0.99	0.64	0.10	1.61	0.56
	1.40	1.01	1.62	1.00	0.82	2.37	0.98	0.74	1.17	1.02	0.74	0.90
	1.39	1.10	1.19	0.64	0.77	0.98	2.39	1.26	1.12	0.66	0.61	0.72
	0.90	1.73	0.61	0.26	0.99	0.74	1.26	2.91	0.55	0.43	0.82	0.77
	1.27	0.94	1.85	0.93	0.64	1.17	1.12	0.55	2.52	0.81	0.45	0.80
	1.15	0.85	1.28	1.49	0.10	1.02	0.66	0.43	0.81	2.19	0.25	0.55
	0.58	0.56	0.61	0.14	1.61	0.74	0.61	0.82	0.45	0.25	2.43	0.54
	0.83	0.70	0.85	0.53	0.56	0.90	0.72	0.77	0.80	0.55	0.54	1.35

Hinnang	λ_1	λ_2	λ_3	λ_4	glb
Väärtus	0.79	0.87	0.86	0.93	0.93

Joonis 13: Valimi kovariatsioonimaatriks koos reliaabluse hinnangutega

Kovariatsioonimaatriks

1.99	0.39	0.37	0.98	0.85	0.70	-0.48	-0.49	-0.39	-0.43	-0.25	-0.27
0.39	2.15	0.38	0.79	0.50	0.28	-0.60	-0.39	-0.27	-0.05	-0.19	-0.05
0.37	0.38	2.12	0.45	0.74	0.70	-0.41	-0.10	-0.06	0.06	-0.02	0.07
0.98	0.79	0.45	3.06	0.95	0.34	-0.59	-0.64	-0.36	-0.14	-0.04	0.05
0.85	0.50	0.74	0.95	2.90	0.77	-0.32	-0.58	-0.05	0.05	0.22	0.32
0.70	0.28	0.70	0.34	0.77	2.65	-0.47	-0.45	-0.45	-0.37	-0.39	-0.38
-0.48	-0.60	-0.41	-0.59	-0.32	-0.47	1.99	0.58	0.51	0.38	0.31	0.47
-0.49	-0.39	-0.10	-0.64	-0.58	-0.45	0.58	1.86	0.59	0.30	0.03	0.31
-0.39	-0.27	-0.06	-0.36	-0.05	-0.45	0.51	0.59	1.63	0.63	0.45	0.81
-0.43	-0.05	0.06	-0.14	0.05	-0.37	0.38	0.30	0.63	1.41	0.63	1.01
-0.25	-0.19	-0.02	-0.04	0.22	-0.39	0.31	0.03	0.45	0.63	1.79	1.11
-0.27	-0.05	0.07	0.05	0.32	-0.38	0.47	0.31	0.81	1.01	1.11	2.33

Hinnang	λ_1	λ_2	λ_3	λ_4	glb
Väärtus	0.39	0.53	0.43	0.68	0.70

Joonis 14: Valimi kovariatsioonimaatriks koos reliaabluse hinnangutega

C Programmiteegi implementatsioon

```
def calculate_lambda_1(cov_matrix):
    u"""
    Based on Guttman,1945, for calculations using Jackson,
    Aguvwamba,1977,[569].
    """
    n = check_that_matrix_is_square_and_fix_n(cov_matrix)
    def sum_of_main_diagonal():
        summ = 0
        for i in xrange(n):
            summ += cov_matrix[i,i]
        return summ

    return 1 - (sum_of_main_diagonal()/
      calculate_sum_of_covariance_matrix_elements(cov_matrix, n))
```

Programm 1: Funktsioon hinnangu λ_1 leidmiseks

```
def calculate_lambda_2(cov_matrix):
    u"""
    Using Guttman,1945,[259] definition.
    """
    def sum_of_squares_of_non_diagonal_matrix_elements():
        summ = 0
        for i in xrange(n):
            for j in xrange(i):
                    summ += cov_matrix[i,j]**2
        return 2*summ

    n = len(cov_matrix)
    l1 = calculate_lambda_1(cov_matrix)
    sum_of_squares = sum_of_squares_of_non_diagonal_matrix_elements()
    under_square_root =((n)/(n-1)* sum_of_squares)**(1/2)
    return l1 + (under_square_root/
        calculate_sum_of_covariance_matrix_elements(cov_matrix))
```

Programm 2: Funktsioon hinnangu λ_2 leidmiseks

```
def calculate_lambda_3(cov_matrix):
    number_of_items = len(cov_matrix)
    return (number_of_items/(number_of_items-1))*calculate_lambda_1(cov_matrix)
```

Programm 3: Funktsioon hinnangu λ_3 leidmiseks

```python
import numpy as np

def calculate_lambda_4(cov_matrix):
    u"""
    Lambda 4, based on Guttman, 1945, using the implementation of Jackson,
    Agunwamba, 1977.
    Based on idea that we try to best possible split (u is a vector,
     with elements either 1 or -1, ones will be in one split,
     minus ones in another) .
    NAIVE IMPLEMENTATION, works with relativiely low N,
    better approches available,  see Benton, 2013.
    """

    def objective_function(u):
        return u.T.dot(cov_matrix.dot(u))


    def try_vectors():
        u"""
        Idea : generate half of all possible vectors of length n,
         such that if vector v is in, vector -v is not.
        Using binary representation as string,
         from 2**(n-1) to 2**n, coding "0" to "-1"
        """
        smallest = np.Infinity
        result_vector = []
        l = []
        for i in xrange(2**(n-1),2**n):
            binary_of_i = np.binary_repr(i,width=n)
            binary_of_i_int = [ 1 if x == u"1" else -1 for x in binary_of_i]
            u = np.array(binary_of_i_int)
            result = objective_function(u)
            if result < smallest:
                smallest = result
                result_vector = u
        return smallest

    def calc_lambda(smallest):
        return 1 - (smallest/
            util.calculate_sum_of_covariance_matrix_elements(cov_matrix, n))

    n = util.check_that_matrix_is_square_and_fix_n(cov_matrix)
    return calc_lambda(try_vectors())
```

Programm 4: Funktsioon hinnangu λ_4 leidmiseks

```python
import cvxpy as cv
import numpy as np

u""""
Idea: Observed covariance matrix  is of observed scores.
That matrix is sum of true score coviarance matrix and error covariance matrix.
As errors don't correlate with anything else than themselves,
 the last is diagonal matrix. So, C_obs = C_true + C_error
We look to maximize error (to find the worst possible case),
that is the same as minimizing the trace of C_true.
More can be found in Jackson,Agunwamba,1977 and Woodhouse,Jakson, 1977.
"""

class Glb(object):
    def __init__(self,cov_matrix):
        self._cov_matrix = cov_matrix
        self._constraints = []
        self._n = util.check_that_matrix_is_square_and_fix_n(cov_matrix)
        self._cov_matrix = np.matrix(cov_matrix)
        self._generate_matrix_variables()
        self._divide_covariance_matrix_of_into_error_and_true_score()
        self._fix_error_cov_matrix_diagonal_fields_constraints()
        self._error_cov_matrix_non_diagonal_fields_are_0()
        self._prepare_program()
        self._solve_program()
        self._answer = self._calculate_Glb()

    def _generate_matrix_variables(self):
        self._true_cov_matrix = cv.semidefinite(self._n,
             name=u"true_cov_matrix")
        self._error_cov_matrix = cv.Variable(self._n, self._n,
            name=u"error_cov_matrix")


    def _divide_covariance_matrix_of_into_error_and_true_score(self):
        u"""
        Constraint that C_obs = C_true + C_error
        """
        self._constraints.append(self._error_cov_matrix+
            self._true_cov_matrix == self._cov_matrix)

    def _fix_error_cov_matrix_diagonal_fields_constraints(self):
        u"""
        Error covariance matrix must be semidefinite,
         meaning that all elements on the diagonal must be positive.
        """
        for i in xrange(self._n):
            self._constraints.append(self._error_cov_matrix[i,i] >= 0)
```

```
    def _error_cov_matrix_non_diagonal_fields_are_0(self):
        u"""
        Covariance between different errors is 0
        """
        for i in xrange(self._n):
            for j in xrange(self._n):
                if (i != j):
                    self._constraints.append(
                        self._error_cov_matrix[i,j] == 0)


    def _prepare_program(self):
        u"""
        Minimize trace of true score covirance matrix
        """
        self._p = cv.Problem(cv.Minimize(
            sum([self._true_cov_matrix[i,i] for i in xrange(self._n)])),
            self._constraints)
        if not self._p.is_dcp():
            raise Exception(u"Non-DCP glb, something went terrible wrong")


    def _solve_program(self):

        try:
            self._p.solve()
        except:
            raise Exception(u"Program was unable to find glb")


    def _calculate_Glb(self):
        return 1 - (sum(
          [self._error_cov_matrix.value[i,i] for i in xrange(self._n)])/
            util.calculate_sum_of_covariance_matrix_elements(
                self._cov_matrix,self._n)


    def get_answer(self):
        return self._answer
```

Programm 5: Klass hinnangu *glb* leidmiseks

```
def check_that_matrix_is_square_and_fix_n(input_matrix):
    def check_that_matrix_is_square():
        for row in input_matrix:
            if len(row) != n:
```

```
                raise Exception(u"Matrix not square or missing data")
    n = len(input_matrix)
    check_that_matrix_is_square()
    return n

def fix_number_of_rows(input_matrix):
    def check_that_matrix_is_complete():
        for row in input_matrix:
            if len(row) != n:
                raise Exception(u"Matrix not square or missing data")
    n = len(input_matrix[0])
    check_that_matrix_is_complete()
    return n


def calculate_sum_of_covariance_matrix_elements(cov_matrix,n = None):
    if n == None:
        n = check_that_matrix_is_square_and_fix_n(cov_matrix)
    summ = 0
    for i in xrange(n):
        for j in xrange(n):
            summ += cov_matrix[i,j]
    return summ
```

Programm 6: Eelnevates programmides kasutatutd abifunktsioonid

D Litsents

Lihtlitsents lõputöö reprodutseerimiseks ja lõputöö üldsusele kättesaadavaks tegemiseks.

Mina, Vootele Rõtov (sünnikuupäev: 11.11.1988)

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) enda loodud teose

   Valikvastustega küsimustike reliaabluse hindamine,

   mille juhendaja on Margus Niitsoo,

   (a) reprodutseerimiseks säilitamise ja üldsusele kättesaadavaks tegemise eesmärgil, sealhulgas digitaalarhiivi DSpace'i lisamise eesmärgil kuni autoriõiguse kehtivuse tähtaja lõppemiseni;

   (b) üldsusele kättesaadavaks tegemiseks Tartu Ülikooli veebikeskkonna kaudu, sealhulgas digitaalarhiivi DSpace'i kaudu kuni autoriõiguse kehtivuse tähtaja lõppemiseni.

2. olen teadlik, et punktis 1 nimetatud õigused jäävad alles ka autorile.

3. kinnitan, et lihtlitsentsi andmisega ei rikuta teiste isikute intellektuaalomandi ega isikuandmete kaitse seadusest tulenevaid õigusi.

Tartu, 31. mai 2014. a.